

2025 年 12 月 30 日



◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ▶ ↺ 🔍 ↻

对比学习

对比学习在时空数据上的应用

生成式方法

② 时空自动机器学习

② 时空自动机器学习

主数据，获取成本高昂

- **传统监督学习严重依赖大量标注数据，获取成本高昂**

数据，获取成本高昂

品，蕴含丰富信息未被有效利用

- 传统监督学习严重依赖大量标注数据，获取成本高昂
- 现实世界中存在海量未标注数据，蕴含丰富信息未被有效利用

数据，获取成本高昂

品，蕴含丰富信息未被有效利用

自动创建监督信号

- 传统监督学习严重依赖大量标注数据，获取成本高昂
- 现实世界中存在海量未标注数据，蕴含丰富信息未被有效利用
- 自监督学习旨在从未标注数据中自动创建监督信号

数据，获取成本高昂

，蕴含丰富信息未被有效利用

自动创建监督信号

（转角度、拼图重组）泛化能力有限

- 传统监督学习严重依赖大量标注数据，获取成本高昂
- 现实世界中存在海量未标注数据，蕴含丰富信息未被有效利用
- 自监督学习旨在从未标注数据中自动创建监督信号
- 早期自监督方法（如预测图像旋转角度、拼图重组）泛化能力有限

数据，获取成本高昂
，蕴含丰富信息未被有效利用
自动创建监督信号
转角度、拼图重组) 泛化能力有限
的自监督学习范式

- 传统监督学习严重依赖大量标注数据，获取成本高昂
- 现实世界中存在海量未标注数据，蕴含丰富信息未被有效利用
- 自监督学习旨在从未标注数据中自动创建监督信号
- 早期自监督方法（如预测图像旋转角度、拼图重组）泛化能力有限
- 研究者寻求一种更通用、更鲁棒的自监督学习范式

数据，获取成本高昂
蕴含丰富信息未被有效利用
自动创建监督信号
(多角度、拼图重组) 泛化能力有限
自监督学习范式
不同样本的特征表示

- 传统监督学习严重依赖大量标注数据，获取成本高昂
- 现实世界中存在海量未标注数据，蕴含丰富信息未被有效利用
- 自监督学习旨在从未标注数据中自动创建监督信号
- 早期自监督方法（如预测图像旋转角度、拼图重组）泛化能力有限
- 研究者寻求一种更通用、更鲁棒的自监督学习范式
- 对比学习应运而生：通过学习区分不同样本的特征表示

据，获取成本高昂
 蕴含丰富信息未被有效利用
 构造监督信号
 (多角度、拼图重组) 泛化能力有限
 自监督学习范式
 不同样本的特征表示
 特征表示对下游任务至关重要

- ◀ ◻ ▶ ◀ ▢ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ↺ 🔍 ↻

为什么要做数据增强?

- 早期的 AI 模型都是端到端学习的，模型直接从原始数据中学习特征表示

为什么要做数据增强？

- 早期的 AI 模型都是端到端学习的，模型直接从原始数据中学习特征表示
- 原始数据通常包含噪声、冗余信息，且样本量有限

为什么要做数据增强?

- 早期的 AI 模型都是端到端学习的，模型直接从原始数据中学习特征表示
- 原始数据通常包含噪声、冗余信息，且样本量有限
- 更大的模型需要更多的数据来避免过拟合

为什么要做数据增强？

- 早期的 AI 模型都是端到端学习的，模型直接从原始数据中学习特征表示
- 原始数据通常包含噪声、冗余信息，且样本量有限
- 更大的模型需要更多的数据来避免过拟合
- 数据增强通过生成更多多样化的训练样本，提升模型的泛化能力

为什么要做数据增强？

- 早期的 AI 模型都是端到端学习的，模型直接从原始数据中学习特征表示
- 原始数据通常包含噪声、冗余信息，且样本量有限
- 更大的模型需要更多的数据来避免过拟合
- 数据增强通过生成更多多样化的训练样本，提升模型的泛化能力
- 增强后的数据帮助模型学习到对输入变换具有不变性的特征表示

图像数据增强的常见方法

- 通过对原始数据进行一系列随机变换，生成多个不同视图，包括但不限于：

图像数据增强的常见方法

- 通过对原始数据进行一系列随机变换, 生成多个不同视图, 包括但不限于:
 - 随机裁剪与缩放

图像数据增强的常见方法

- 通过对原始数据进行一系列随机变换，生成多个不同视图，包括但不限于：
 - 随机裁剪与缩放
 - 水平翻转

图像数据增强的常见方法

- 通过对原始数据进行一系列随机变换，生成多个不同视图，包括但不限于：
 - 随机裁剪与缩放
 - 水平翻转
 - 颜色抖动（亮度、对比度、饱和度调整）

图像数据增强的常见方法

- 通过对原始数据进行一系列随机变换，生成多个不同视图，包括但不限于：
 - 随机裁剪与缩放
 - 水平翻转
 - 颜色抖动（亮度、对比度、饱和度调整）
 - 高斯噪声添加

图像数据增强的常见方法

- 通过对原始数据进行一系列随机变换，生成多个不同视图，包括但不限于：
 - 随机裁剪与缩放
 - 水平翻转
 - 颜色抖动（亮度、对比度、饱和度调整）
 - 高斯噪声添加
 - 随机旋转与仿射变换

文本数据增强的常见方法

- **同义词替换:** 用同义词替换句子中的部分单词。

文本数据增强的常见方法

- **同义词替换**：用同义词替换句子中的部分单词。
- **随机插入**：在句子中随机位置插入一个词。

文本数据增强的常见方法

- **同义词替换**：用同义词替换句子中的部分单词。
- **随机插入**：在句子中随机位置插入一个词。
- **随机删除**：随机删除句子中的某些单词。

文本数据增强的常见方法

- **同义词替换**：用同义词替换句子中的部分单词。
- **随机插入**：在句子中随机位置插入一个词。
- **随机删除**：随机删除句子中的某些单词。
- **随机交换**：随机交换句子中两个单词的位置。

基本多样性，但存在一些固有限制：

- 数据增强虽然能有效增加训练样本多样性，但存在一些固有限制：

样本多样性，但存在一些固有限制：
难以生成完全新颖的数据点。

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ◀ ↺ 🔍 ↻

本多样性，但存在一些固有限制：
难以生成完全新颖的数据点。
的变换可能不足以捕捉数据的本质特征。

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ 🔍 ↺

本多样性，但存在一些固有限制：
难以生成完全新颖的数据点。
的变换可能不足以捕捉数据的本质特征。
仍可能过于相似，导致模型过拟合。

- 数据增强虽然能有效增加训练样本多样性，但存在一些固有限制：
 - 只能在已知变换范围内操作，难以生成完全新颖的数据点。
 - 对于复杂模式识别任务，简单的变换可能不足以捕捉数据的本质特征。
 - 在高维空间中，增强后的样本仍可能过于相似，导致模型过拟合。

本多样性，但存在一些固有限制：
难以生成完全新颖的数据点。
的变换可能不足以捕捉数据的本质特征。
仍可能过于相似，导致模型过拟合。
规则（如旋转、翻转等），这限制了其泛化

- 数据增强虽然能有效增加训练样本多样性，但存在一些固有限制：
 - 只能在已知变换范围内操作，难以生成完全新颖的数据点。
 - 对于复杂模式识别任务，简单的变换可能不足以捕捉数据的本质特征。
 - 在高维空间中，增强后的样本仍可能过于相似，导致模型过拟合。
- 数据增强主要依赖于人工定义的规则（如旋转、翻转等），这限制了其泛化能力。

基本多样性，但存在一些固有限制：
难以生成完全新颖的数据点。
变换可能不足以捕捉数据的本质特征。
仍可能过于相似，导致模型过拟合。
规则（如旋转、翻转等），这限制了其泛化
的情况下，从大量未标注数据中学习到的更有

- 数据增强虽然能有效增加训练样本多样性，但存在一些固有限制：
 - 只能在已知变换范围内操作，难以生成完全新颖的数据点。
 - 对于复杂模式识别任务，简单的变换可能不足以捕捉数据的本质特征。
 - 在高维空间中，增强后的样本仍可能过于相似，导致模型过拟合。
- 数据增强主要依赖于人工定义的规则（如旋转、翻转等），这限制了其泛化能力。
- 需要一种方法能够在没有明确标签的情况下，从大量未标注数据中学习到更有意义的特征表示。

A large, faint, circular watermark of the Fuzhou University logo is centered on the page. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top arc and in Chinese, "福州大学", around the bottom arc. The year "1958" is positioned at the bottom center of the circle. In the middle of the logo is a large, stylized Chinese character "福" (Fú), which is a common symbol for good fortune. The entire watermark is rendered in a light gray or off-white color, serving as a background element.

- 数据增强:

限。

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ≡ ↺ 🔍 ↻

限。

A large, faint, circular watermark of the Fuzhou University logo is centered in the background. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top arc and in Chinese, "福州大学", around the bottom arc, with the year "1958" at the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú), which is also the first character of "Fuzhou".

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ▶ ↺ 🔍 ↻

限。

- 数据增强：
 - 增加样本量，但样本间差异有限。
 - 主要用于提高模型的鲁棒性。
 - 依赖于预定义的转换规则。

限。

- 数据增强：
 - 增加样本量，但样本间差异有限。
 - 主要用于提高模型的鲁棒性。
 - 依赖于预定义的转换规则。
- 对比学习：

限。

简单地增加样本数量。

- 数据增强：
 - 增加样本量，但样本间差异有限。
 - 主要用于提高模型的鲁棒性。
 - 依赖于预定义的转换规则。
- 对比学习：
 - 学习深层次的特征表示，而非简单地增加样本数量。

限。

简单地增加样本数量。
来学习特征。

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡

限。

简单地增加样本数量。
来学习特征。
加灵活和强大。

- A set of small navigation icons typically found in Beamer presentations, including symbols for back, forward, search, and other slide controls.

限。

简单地增加样本数量。
来学习特征。
加灵活和强大。

能，特别是在处理复杂的时空数据时。

- 数据增强：
 - 增加样本量，但样本间差异有限。
 - 主要用于提高模型的鲁棒性。
 - 依赖于预定义的转换规则。
- 对比学习：
 - 学习深层次的特征表示，而非简单地增加样本数量。
 - 通过比较不同样本之间的关系来学习特征。
 - 不局限于特定的变换方式，更加灵活和强大。
- 结合两者可以进一步提升模型性能，特别是在处理复杂的时空数据时。

样本靠近，不相似样本远离

- A set of small navigation icons typically found in Beamer presentations, including symbols for back, forward, search, and other slide controls.

样本靠近，不相似样本远离

样本对)

空间

- **核心思想：**学习表示使得相似样本靠近，不相似样本远离
- **基本组件：**
 - 样本 x 及其增强版本 x^+ （正样本对）
 - 其他样本 x^- （负样本）
 - 编码器 $f(\cdot)$ 将样本映射到特征空间

样本靠近，不相似样本远离

样本对)

空间

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ▶ ↺ 🔍 ↻

样本靠近，不相似样本远离


样本对)

空间

- 似”


“让相似的更相似，不相似的更不相似”

- **端到端对比学习:**



- **端到端对比学习：**
 - 使用当前批次的样本作为负样本

端到端对比学习



- **端到端对比学习:**
 - 使用当前批次的样本作为负样本
 - 编码器同时处理查询和键

The diagram illustrates the End-to-End Contrastive Learning process. At the bottom, a green box labeled '当前 Batch' (Current Batch) feeds into a blue box labeled '编码器' (Encoder). The output of the encoder is a red dot labeled '负样本' (Negative Sample). Above this, a blue dot is labeled '正样本对' (Positive Sample Pair), with a blue double-headed arrow indicating the distance between the two dots. A red double-headed arrow indicates the distance between the negative sample and the positive sample pair. The entire process is labeled '端到端对比学习' (End-to-End Contrastive Learning) at the bottom.

- 
- The diagram illustrates the end-to-end contrastive learning process. At the bottom, a green box labeled "当前 Batch" (Current Batch) feeds into a purple box labeled "编码器" (Encoder). The encoder outputs a set of red dots representing embeddings. These embeddings are used to form "正样本对" (Positive Sample Pairs), shown as two blue dots connected by a blue double-headed arrow, and "负样本" (Negative Samples), shown as a red dot with a red arrow pointing away from the positive pair. The entire process is labeled "端到端对比学习" (End-to-End Contrastive Learning) at the bottom.

- **端到端对比学习:**
 - 使用当前批次的样本作为负样本
 - 编码器同时处理查询和键
 - 需要极大的批次大小 (4096+)

The diagram illustrates the end-to-end contrastive learning process. At the bottom, a green box labeled '当前 Batch' (Current Batch) feeds into a purple box labeled '编码器' (Encoder). The encoder's output is shown as a set of red dots, with one dot labeled '负样本' (Negative Sample). Above this, a blue box labeled '正样本对' (Positive Sample Pair) shows two blue dots connected by a blue double-headed arrow, representing a positive sample pair. A red double-headed arrow connects one of the red dots to the positive sample pair, indicating the contrastive learning process. The text '端到端对比学习' (End-to-End Contrastive Learning) is written at the bottom right of the diagram.

- 
- The diagram illustrates the end-to-end contrastive learning process. At the bottom, a green box labeled "当前 Batch" (Current Batch) has an upward arrow pointing to a purple box labeled "编码器" (Encoder). From the encoder, an upward arrow points to a red dot labeled "负样本" (Negative Sample). Above this, a blue dot and a blue dot are connected by a blue double-headed arrow, labeled "正样本对" (Positive Sample Pair). A red arrow points from the "负样本" dot to the "正样本对" dots, indicating the distance or contrast.

- **端到端对比学习：**
 - 使用当前批次的样本作为负样本
 - 编码器同时处理查询和键
 - 需要极大的批次大小 (4096+)
- **基于存储库的方法：**

The diagram illustrates the process of end-to-end contrastive learning. At the bottom, a green box labeled '当前 Batch' (Current Batch) feeds into a purple box labeled '编码器' (Encoder). The encoder's output is shown as a cluster of points. A horizontal blue double-headed arrow between two points is labeled '正样本对' (Positive Sample Pair). A vertical red double-headed arrow between a point from the encoder's output and a separate red point is labeled '负样本' (Negative Sample). Below the diagram, the text '端到端对比学习' (End-to-End Contrastive Learning) is displayed.

- 
- The diagram illustrates the end-to-end contrastive learning process. At the bottom, a green box labeled "当前 Batch" (Current Batch) has an upward arrow pointing to a purple box labeled "编码器" (Encoder). From the encoder, an upward arrow points to a cluster of red dots labeled "负样本" (Negative Samples). Above the negative samples, a blue dot and a red dot are connected by a blue double-headed arrow, labeled "正样本对" (Positive Sample Pair). A red arrow points from the red dot in the positive pair down to the red dots in the negative sample cluster.


- **端到端对比学习：**
 - 使用当前批次的样本作为负样本
 - 编码器同时处理查询和键
 - 需要极大的批次大小（4096+）
- **基于存储库的方法：**
 - 维护一个特征存储库

The diagram illustrates the process of end-to-end contrastive learning. At the bottom, a green box labeled '当前 Batch' (Current Batch) feeds into a purple box labeled '编码器' (Encoder). The encoder's output is represented by a vertical stack of red dots. A horizontal blue double-headed arrow at the top of these dots is labeled '正样本对' (Positive Sample Pair). A vertical red double-headed arrow between the top dot and the rest of the stack is labeled '负样本' (Negative Sample). The entire diagram is captioned '端到端对比学习' (End-to-End Contrastive Learning) at the bottom.

-
- The diagram illustrates the components of triplet loss. At the bottom is a green box labeled "当前 Batch" (Current Batch). An arrow points up to a purple box labeled "编码器" (Encoder). From the encoder, an arrow points up to a group of red dots labeled "负样本" (Negative Samples). Above the negative samples, two blue dots are connected by a horizontal blue double-headed arrow, labeled "正样本对" (Positive Sample Pairs). A vertical red double-headed arrow connects one of the red dots to the lower blue dot, representing the distance between a negative and a positive sample.

传统对比学习方法

- **端到端对比学习：**
 - 使用当前批次的样本作为负样本
 - 编码器同时处理查询和键
 - 需要极大的批次大小（4096+）
- **基于存储库的方法：**
 - 维护一个特征存储库
 - 从存储库中采样负样本



- **端到端对比学习：**
 - 使用当前批次的样本作为负样本
 - 编码器同时处理查询和键
 - 需要极大的批次大小（4096+）
- **基于存储库的方法：**
 - 维护一个特征存储库
 - 从存储库中采样负样本
 - 内存效率更高

The diagram illustrates the End-to-End Contrastive Learning process. At the bottom, a green box labeled '当前 Batch' (Current Batch) feeds into a purple box labeled '编码器' (Encoder). The encoder outputs a representation, which is then compared with a '正样本对' (Positive Sample Pair) shown as two blue dots with a double-headed arrow between them. A '负样本' (Negative Sample) is shown as a red dot, with a red arrow indicating its distance from the positive pair. The entire process is labeled '端到端对比学习' (End-to-End Contrastive Learning) at the bottom.

-
- The diagram illustrates the components of triplet loss. At the bottom is a green box labeled "当前 Batch" (Current Batch). An arrow points up to a purple box labeled "编码器" (Encoder). From the encoder, an arrow points up to a group of red dots labeled "负样本" (Negative Samples). Above the negative samples is a pair of blue dots connected by a horizontal blue double-headed arrow, labeled "正样本对" (Positive Sample Pairs). A vertical red double-headed arrow connects the positive sample pair to the negative samples.

ve Estimation):

$$\frac{\exp(f(x)^\top f(x^+)/\tau)}{f(x^+)/\tau) + \sum_{i=1}^N \exp(f(x)^\top f(x_i^-)/\tau)} \Big]$$

- $$\mathcal{L} = -\mathbb{E} \left[\log \frac{\exp(f(x)^\top f(x^+)/\tau)}{\exp(f(x)^\top f(x^+)/\tau) + \sum_{i=1}^N \exp(f(x)^\top f(x_i^-)/\tau)} \right]$$

Temperature-scaled Cross Entropy):

$$\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k \neq i} \exp(\text{sim}(z_i, z_k)/\tau)}$$

- $$\mathcal{L} = -\mathbb{E} \left[\log \frac{\exp(f(x)^\top f(x^+)/\tau)}{\exp(f(x)^\top f(x^+)/\tau) + \sum_{i=1}^N \exp(f(x)^\top f(x_i^-)/\tau)} \right]$$

- $$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k \neq i} \exp(\text{sim}(z_i, z_k)/\tau)}$$

Temperature-scaled Cross Entropy):

$$\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k \neq i} \exp(\text{sim}(z_i, z_k)/\tau)}$$

- $$\mathcal{L} = -\mathbb{E} \left[\log \frac{\exp(f(x)^\top f(x^+)/\tau)}{\exp(f(x)^\top f(x^+)/\tau) + \sum_{i=1}^N \exp(f(x)^\top f(x_i^-)/\tau)} \right]$$

- $$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k \neq i} \exp(\text{sim}(z_i, z_k)/\tau)}$$

- ### ● 关键参数:

Temperature-scaled Cross Entropy):

$$\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k \neq i} \exp(\text{sim}(z_i, z_k)/\tau)}$$

- τ : 温度参数, 控制分布集中度

Temperature-scaled Cross Entropy):

$$\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k \neq i} \exp(\text{sim}(z_i, z_k)/\tau)}$$

- $$\mathcal{L} = -\mathbb{E} \left[\log \frac{\exp(f(x)^\top f(x^+)/\tau)}{\exp(f(x)^\top f(x^+)/\tau) + \sum_{i=1}^N \exp(f(x)^\top f(x_i^-)/\tau)} \right]$$

- $$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k \neq i} \exp(\text{sim}(z_i, z_k)/\tau)}$$

- τ : 温度参数, 控制分布集中度
- N : 负样本数量


Temperature-scaled Cross Entropy):

$$\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k \neq i} \exp(\text{sim}(z_i, z_k)/\tau)}$$


余弦相似度)

- τ : 温度参数, 控制分布集中度
- N : 负样本数量
- $\text{sim}(\cdot, \cdot)$: 相似度度量 (通常为余弦相似度)

- 授课教师：柯嵩宇




- **温度参数 τ** 控制相似度分布的平滑度
- **τ 较小** (如 0.07):
 - 分布更“尖锐”
 - 关注最困难的负样本



不同 τ 值的相似度分布


- **温度参数 τ** 控制相似度分布的平滑度
- τ **较小** (如 0.07):
 - 分布更“尖锐”
 - 关注最困难的负样本
 - 可能导致训练不稳定



不同 τ 值的相似度分布


- $\left| \frac{\partial}{\partial x} \tau = 1 \right|_0$

-
- 不同 τ 值的相似度分布



通常 τ 在 0.05 到 0.2 之间，需要根据具体任务调整

-
- 不同 τ 值的相似度分布



-

不同 τ 值的相似度分布

通常 τ 在 0.05 到 0.2 之间，需要根据具体任务调整

通常 τ 在 0.05 到 0.2 之间，需要根据具体任务调整

- **什么是模型塌缩?**
 - 所有输入映射到同一输出特征
 - 特征空间完全退化
 - 模型“偷懒”但损失仍然很低

模型塌缩示意图

- 正常 
- 塌缩 所有样本 
- 模型塌缩示意图

- **什么是模型塌缩?**
 - 所有输入映射到同一输出特征
 - 特征空间完全退化
 - 模型“偷懒”但损失仍然很低
- **为什么会发生?**
 - 损失函数对称性导致的平凡解
 - 缺乏有效的负样本约束
 - 网络容量过大而数据有限

- **什么是模型塌缩？**
 - 所有输入映射到同一输出特征
 - 特征空间完全退化
 - 模型“偷懒”但损失仍然很低
- **为什么会发生？**
 - 损失函数对称性导致的平凡解
 - 缺乏有效的负样本约束
 - 网络容量过大而数据有限

正常

塌缩

所有样本

模型塌缩示意图

- **什么是模型塌缩?**
 - 所有输入映射到同一输出特征
 - 特征空间完全退化
 - 模型“偷懒”但损失仍然很低
- **为什么会发生?**
 - 损失函数对称性导致的平凡解
 - 缺乏有效的负样本约束
 - 网络容量过大而数据有限

正常

塌缩 所有样本

模型塌缩示意图

- **什么是模型塌缩？**
 - 所有输入映射到同一输出特征
 - 特征空间完全退化
 - 模型“偷懒”但损失仍然很低
- **为什么会发生？**
 - 损失函数对称性导致的平凡解
 - 缺乏有效的负样本约束
 - 网络容量过大而数据有限

正常

塌缩

所有样本

模型塌缩示意图

塌缩问题的严重性

一旦发生模型塌缩，网络将完全失去表示能力，无法区分任何输入样本！

对相似度为 s^+ , 负样本相似度为 s^-

$$\frac{\exp(s^+/\tau)}{\exp(s^+/\tau) + \sum \exp(s^-/\tau)}$$

- $$\mathcal{L} = -\log \frac{\exp(s^+/\tau)}{\exp(s^+/\tau) + \sum \exp(s^-/\tau)}$$

对相似度为 s^+ ，负样本相似度为 s^-

$$= \frac{\exp(s^+/\tau)}{\exp(s^+/\tau) + \sum \exp(s^-/\tau)}$$

数函数)，则：

$$= s^- = \text{sim}(c, c) = 1$$
$$\log \frac{1}{1+N} = \log(1+N)$$

络走向这个方向

- $$\mathcal{L} = -\log \frac{\exp(s^+/\tau)}{\exp(s^+/\tau) + \sum \exp(s^-/\tau)}$$

- $$s^+ = s^- = \text{sim}(c, c) = 1$$

损失变为：

$$\mathcal{L} = -\log \frac{1}{1+N} = \log(1+N)$$

这不是最小值！但梯度可能推动网络走向这个方向

- $$\frac{\partial \mathcal{L}}{\partial s^-} = \frac{\exp(s^-/\tau)}{\sum \exp(s/\tau)}$$

◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ≡ ≡ ↺ 🔍 ↻

A large, faint watermark of the Fuzhou University logo is centered on the page. The logo is circular, featuring the university's name in English, "FUZHOU UNIVERSITY", around the top and the Chinese characters "福州大学" around the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú), which means "blessing" or "good fortune". Below the character "福" is the year "1958". At the very bottom of the page, there is a small navigation bar with several icons: a square, a circle, a triangle, and a series of arrows.

- **大批次训练:**
 - 提供更多负样本
 - 增加对比的多样性
 - 但计算成本高

A large, faint, circular watermark of the Fuzhou University logo is centered on the page. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top arc and in Chinese, "福州大学", around the bottom arc. The year "1958" is positioned at the bottom center of the circle. In the middle of the logo is a large, stylized Chinese character "福" (Fú), which is a common symbol for good fortune. The entire watermark is rendered in a light gray or off-white color, serving as a background element.

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ≡ ↺ 🔍 ↻

- **预测头 (Projection Head):**
 - 将特征映射到对比空间
 - 防止主干网络塌缩
 - 增强表示能力

- **预测头 (Projection Head):**
 - 将特征映射到对比空间
 - 防止主干网络塌缩
 - 增强表示能力

- **预测头 (Projection Head):**
 - 将特征映射到对比空间
 - 防止主干网络塌缩
 - 增强表示能力
- **停止梯度 (Stop Gradient):**
 - 在某些分支阻止梯度传播
 - 打破对称性
 - BYOL 中的关键技巧

- **预测头 (Projection Head):**
 - 将特征映射到对比空间
 - 防止主干网络塌缩
 - 增强表示能力
- **停止梯度 (Stop Gradient):**
 - 在某些分支阻止梯度传播
 - 打破对称性
 - BYOL 中的关键技巧

- **预测头 (Projection Head):**
 - 将特征映射到对比空间
 - 防止主干网络塌缩
 - 增强表示能力
- **停止梯度 (Stop Gradient):**
 - 在某些分支阻止梯度传播
 - 打破对称性
 - BYOL 中的关键技巧

- **预测头 (Projection Head):**
 - 将特征映射到对比空间
 - 防止主干网络塌缩
 - 增强表示能力
- **停止梯度 (Stop Gradient):**
 - 在某些分支阻止梯度传播
 - 打破对称性
 - BYOL 中的关键技巧

SimCLR 发现：批次大小从 256 增加到 8192 时，ImageNet 上的线性评估准确率从 51% 提升到 70%！

SimCLR 发现：批次大小从 256 增加到 8192 时，ImageNet 上的线性评估准确率从 51% 提升到 70%！

A large, faint watermark of the Fuzhou University logo is centered on the page. The logo is circular, featuring the university's name in English, "FUZHOU UNIVERSITY", around the top and the Chinese characters "福州大学" around the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú), which means "blessing" or "good fortune". Below the character "福" is the year "1958". At the very bottom of the page, there is a small navigation bar with several icons: a square, a circle, a triangle, and a series of arrows.

- **计算资源要求高：**
 - 大批次需要大量 GPU 内存
 - 限制了模型规模和训练效率
 - 对小规模研究不友好

- **计算资源要求高：**
 - 大批次需要大量 GPU 内存
 - 限制了模型规模和训练效率
 - 对小规模研究不友好
- **负样本质量不稳定：**
 - 批次内负样本可能包含假阴性
 - 批次间特征不一致
 - 影响对比效果

- **计算资源要求高：**
 - 大批次需要大量 GPU 内存
 - 限制了模型规模和训练效率
 - 对小规模研究不友好
- **负样本质量不稳定：**
 - 批次内负样本可能包含假阴性
 - 批次间特征不一致
 - 影响对比效果
- **难以扩展：**
 - 批次大小有物理限制
 - 特征存储和检索效率低
 - 难以处理大规模数据

解决了这些难题

- 解决了这些难题

解决了这些难题

解决了这些难题

对比学习领域的重要工作，其演进路径展示了从静态到动态的演进，引入动态字典和动量编码器

- MoCo v1 (2019): 开创性工作, 引入动态字典和动量编码器

对比学习领域的重要工作，其演进路径展示了

引入动态字典和动量编码器

R 的改进，性能显著提升

MoCo(Momentum Contrast) 系列是对比学习领域的重要工作，其演进路径展示了对比学习的发展趋势：

- **MoCo v1 (2019):** 开创性工作, 引入动态字典和动量编码器
- **MoCo v2 (2020):** 引入 SimCLR 的改进, 性能显著提升

对比学习领域的重要工作，其演进路径展示了

- 引入动态字典和动量编码器
- 对 R 的改进，性能显著提升
- 移除队列结构，使用 ViT 编码器

MoCo(Momentum Contrast) 系列是对比学习领域的重要工作，其演进路径展示了对比学习的发展趋势：

- **MoCo v1 (2019):** 开创性工作, 引入动态字典和动量编码器
- **MoCo v2 (2020):** 引入 SimCLR 的改进, 性能显著提升
- **MoCo v3 (2021):** 架构优化, 移除队列结构, 使用 ViT 编码器

对比学习领域的重要工作，其演进路径展示了

- 引入动态字典和动量编码器
- 对 R 的改进，性能显著提升
- 移除队列结构，使用 ViT 编码器
- (collapse)
- 退化的现象

核心问题：解决“模型塌缩”(model collapse)

- 模型将所有样本映射到同一特征点的退化现象


对比学习领域的重要工作，其演进路径展示了

- 引入动态字典和动量编码器
- 对 R 的改进，性能显著提升
- 移除队列结构，使用 ViT 编码器
- (collapse)
- 退化的现象
- (空异质性)

核心问题：解决“模型塌缩”(model collapse)

- 模型将所有样本映射到同一特征点的退化现象
- 在城市时空数据中尤为重要（时空异质性）

- **核心创新：动态字典 + 动量编码器**




MoCo v1 架构示意图

- **核心创新**: 动态字典 + 动量编码器
- **队列 (queue)**: 存储历史样本特征作为负样本库

The diagram illustrates the MoCo v1 architecture. It shows a query input x^{query} being processed by an encoder to produce a query feature q . Simultaneously, a set of key inputs $x_0^{\text{key}}, x_1^{\text{key}}, x_2^{\text{key}}, \dots$ is processed by a momentum encoder to produce key features $k_0, k_1, k_2, \dots$. These key features are stored in a queue. The query feature q and the key features from the queue are then compared using a similarity function to calculate a contrastive loss.

MoCo v1 架构示意图



The diagram illustrates the MoCo v1 architecture. It shows a query input x^{query} being processed by an encoder to produce a query feature q . A key input x^{key} (represented as $x_0^{\text{key}}, x_1^{\text{key}}, x_2^{\text{key}}, \dots$) is processed by a momentum encoder to produce key features $k_0, k_1, k_2, \dots$, which are stored in a queue. The query feature q is then compared with the keys in the queue using a similarity function to calculate a contrastive loss. The diagram also includes a red watermark 'FUZHOU UNIVERSITY' and a red '1958' at the bottom.


-
- Diagram illustrating the Contrastive Loss function:
- The **encoder** takes the query input x^{query} and outputs the query vector q .
 - The **momentum encoder** takes a sequence of key inputs $x_0^{\text{key}}, x_1^{\text{key}}, x_2^{\text{key}}, \dots$ and outputs a sequence of key vectors $k_0, k_1, k_2, \dots$ stored in the **queue**.
 - The **similarity** is calculated between the query vector q and the key vectors in the queue.
 - The **contrastive loss** is derived from the similarity.

MoCo v1 架构示意图

- **核心创新**: 动态字典 + 动量编码器
- **队列 (queue)**: 存储历史样本特征作为负样本库
- **动量编码器**: $\theta_k = m\theta_k + (1 - m)\theta_q$
- **损失函数**: InfoNCE 损失

The diagram illustrates the MoCo v1 architecture. A query input x^{query} is processed by an encoder to produce a query feature q . A set of key inputs $x_0^{\text{key}}, x_1^{\text{key}}, x_2^{\text{key}}, \dots$ is processed by a momentum encoder to produce key features $k_0, k_1, k_2, \dots$, which are stored in a queue. The query feature q and the key features from the queue are compared using a similarity function to calculate the contrastive loss.


MoCo v1 架构示意图



- **核心创新**: 动态字典 + 动量编码器
- **队列 (queue)**: 存储历史样本特征作为负样本库
- **动量编码器**: $\theta_k = m\theta_k + (1 - m)\theta_q$
- **损失函数**: InfoNCE 损失
- **优势**: 避免模型塌缩, 支持小批次训练

The diagram illustrates the MoCo v1 architecture. It shows a query input x^{query} being processed by an encoder to produce a query feature q . Simultaneously, key inputs $x_0^{\text{key}}, x_1^{\text{key}}, x_2^{\text{key}}, \dots$ are processed by a momentum encoder to produce key features $k_0, k_1, k_2, \dots$. These key features are stored in a queue. The query feature q is then compared with the features in the queue using a similarity function to calculate a contrastive loss.

MoCo v1 架构示意图



特征表示

- **核心问题：**对比学习需要稳定的特征表示

特征表示
器生成正负样本

- 特征表示
器生成正负样本

特征表示
器生成正负样本

码器
通过梯度下降更新
通过动量更新缓慢变化

- 特征表示
器生成正负样本
- 码器
通过梯度下降更新
通过动量更新缓慢变化

为什么需要两个编码器?

对比学习的目标是让相似的样本特征接近，不相似的远离。
如果编码器变化太快，之前计算的“不相似样本”特征可能已经过时。

20 / 89

θ_q

The diagram illustrates the momentum update process. It shows two rows of boxes. The top row has a blue box labeled $\theta_q(t)$ on the left and a blue box labeled $\theta_q(t+1)$ on the right. A solid blue arrow points from $\theta_q(t)$ to $\theta_q(t+1)$ with the label "SGD 更新" above it. The bottom row has a red box labeled $\theta_k(t)$ on the left and a red box labeled $\theta_k(t+1)$ on the right. A solid red arrow points from $\theta_k(t)$ to $\theta_k(t+1)$ with the label $m \cdot \theta_k + (1 - m)\theta_q$ above it. A dashed blue arrow points from $\theta_q(t)$ down to $\theta_k(t)$. Below the red arrow, the text "动量更新过程" is written.

SGD 更新

$\theta_q(t)$

$\theta_q(t+1)$

$\theta_k(t)$

$\theta_k(t+1)$

$m \cdot \theta_k + (1 - m)\theta_q$

动量更新过程


平均
 θ_q 的信息
剧烈变化

- **更新机制特点:**

$$\theta_k \leftarrow m \cdot \theta_k + (1 - m) \cdot \theta_q$$

其中：


- θ_q : 在线编码器参数
- θ_k : 动量编码器参数
- m : 动量系数 (通常 0.999)



动量更新过程

- **缓慢变化**: θ_k 是 θ_q 的指数移动平均
- **历史信息保留**: 包含过去多个 θ_q 的信息
- **平滑过渡**: 避免特征表示的剧烈变化

- **队列存储历史特征:**



动量编码器与队列协同工作

动量编码器

最新特征
队列
最早特征

对比损失


在线编码器

动量编码器与队列协同工作

-
- The diagram illustrates the relationship between the Momentum Encoder and the Online Encoder. A red box labeled "动量编码器" (Momentum Encoder) has a red arrow pointing to a green box labeled "最新特征" (Latest Feature) and "队列" (Queue). A blue box labeled "在线编码器" (Online Encoder) has a blue arrow pointing to the same green box. The green box also has a blue arrow pointing to a circle labeled "对比损失" (Contrastive Loss). A dashed blue arrow points from the "对比损失" circle back to the "在线编码器".

动量编码器与队列协同工作

- **队列存储历史特征：**
 - 存储过去批次样本的特征
 - 每个特征由动量编码器计算



动量编码器与队列协同工作

动量编码器与队列协同工作

-
- 动量编码器与队列协同工作

动量编码器与队列协同工作


The diagram illustrates the collaborative work of a Momentum Encoder and a Queue. It features three main components: a red box labeled '动量编码器' (Momentum Encoder), a green box labeled '最新特征' (Latest Feature) and '最早特征' (Earliest Feature), and a blue box labeled '在线编码器' (Online Encoder). A red arrow points from the Momentum Encoder to the Queue. A black arrow points from the Queue to a circle labeled '对比损失' (Contrastive Loss). A solid blue arrow points from the Online Encoder to the Queue. A dashed blue arrow points from the Queue to the Online Encoder. A solid blue arrow points from the Online Encoder to the Contrastive Loss circle. A dashed blue arrow points from the Queue to the Contrastive Loss circle.

动量编码器与队列协同工作

- ## 动量编码器与队列协同工作

- **队列存储历史特征：**
 - 存储过去批次样本的特征
 - 每个特征由**动量编码器**计算
 - 队列先进先出，保持最新特征
- **协同工作原理：**
 - 动量编码器缓慢变化 $\rightarrow$ 队列特征相对一致

动量编码器与队列协同工作



-
- The diagram illustrates the architecture of the Momentum Encoder and Online Encoder. It features three main components: a Momentum Encoder (red box), an Online Encoder (blue box), and a Feature Queue (green box). The Momentum Encoder outputs features to the Feature Queue. The Online Encoder also outputs features to the Feature Queue. The Feature Queue stores the latest features (最新特征) and the earliest features (最早特征). The contrastive loss (对比损失) is calculated based on the features from the Momentum Encoder and the Online Encoder. The Online Encoder is updated from the Momentum Encoder via a dashed blue arrow, representing the momentum update.
- ```
graph LR; ME[动量编码器] -- red arrow --> FQ[最新特征
队列
最早特征]; OE[在线编码器] -- blue arrow --> FQ; FQ -- black arrow --> CL((对比损失)); OE -. dashed blue arrow .-> ME; OE -- blue arrow --> CL
```

## 动态编码器与队列协同工作

---

- 
- The diagram illustrates the architecture of the Momentum Encoder and Online Encoder. It features three main components: a Momentum Encoder (red box), an Online Encoder (blue box), and a Feature Queue (green box). The Momentum Encoder outputs features to the Feature Queue. The Online Encoder takes input from the Feature Queue and outputs features to the Feature Queue. The Feature Queue stores the latest features (最新特征) and the earliest features (最早特征). The output of the Online Encoder is used to calculate the Contrastive Loss (对比损失).
- ```
graph LR; ME[动量编码器] -- red arrow --> FQ[最新特征  
队列  
最早特征]; OE[在线编码器] -- blue arrow --> FQ; FQ -- black arrow --> CL((对比损失)); FQ -. dashed blue arrow .-> OE; FQ -- solid blue arrow --> CL;
```

法官助理明长队到法院工作

器生成
有一致性
,

1

- 负样本特征由缓慢变化的编码器生成
- 不同时间生成的负样本特征具有一致性
- 为对比学习提供稳定的“锚点”

器生成
有一致性

批次大小 - 1
小 (可非常大)
得大量负样本

- 负样本特征由缓慢变化的编码器生成
- 不同时间生成的负样本特征具有一致性
- 为对比学习提供稳定的“锚点”

- 传统对比学习：负样本数量 = 批次大小 - 1
- MoCo：负样本数量 = 队列大小（可非常大）
- 允许使用小批次训练，同时获得大量负样本

器生成
有一致性
,
批次大小 - 1
小 (可非常大)
得大量负样本
)
所有样本映射到同一点
, 防止这种退化
的负样本

- 负样本特征由缓慢变化的编码器生成
- 不同时间生成的负样本特征具有一致性
- 为对比学习提供稳定的“锚点”

- 传统对比学习：负样本数量 = 批次大小 - 1
- MoCo：负样本数量 = 队列大小（可非常大）
- 允许使用小批次训练，同时获得大量负样本

- 如果编码器变化太快，可能将所有样本映射到同一点
- 动量编码器提供稳定的参考点，防止这种退化
- 在线编码器必须区分这些稳定的负样本

年提出，无需专用架构或内存库的自监督学习

- A set of small navigation icons typically found in Beamer presentations, including symbols for back, forward, search, and other slide controls.

年提出，无需专用架构或内存库的自监督学习

在数据中学习高质量的视觉表征

- **提出背景:** Hinton 团队于 2020 年提出, 无需专用架构或内存库的自监督学习框架
- **核心目标:** 通过对比学习从无标签数据中学习高质量的视觉表征

年提出，无需专用架构或内存库的自监督学习

在数据中学习高质量的视觉表征

6.5%的 Top-1 准确率，较之前最佳结果提升 7

- **提出背景:** Hinton 团队于 2020 年提出, 无需专用架构或内存库的自监督学习框架
- **核心目标:** 通过对比学习从无标签数据中学习高质量的视觉表征
- **突出成果:** 在 ImageNet 上达到 76.5% 的 Top-1 准确率, 较之前最佳结果提升 7%

提出，无需专用架构或内存库的自监督学习

在数据中学习高质量的视觉表征

6.5%的 Top-1 准确率，较之前最佳结果提升 7%

负样本，拉近相似样本特征，推远不相似样本

- 提出，无需专用架构或内存库的自监督学习
- 在数据中学习高质量的视觉表征
- 6.5%的 Top-1 准确率，较之前最佳结果提升 7%
- 负样本，拉近相似样本特征，推远不相似样本

A large, faint watermark of the Fuzhou University logo is centered on the page. The logo is circular, featuring the university's name in English, "FUZHOU UNIVERSITY", around the top and the Chinese characters "福州大学" around the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú), which means "blessing" or "good fortune". Below the character "福" is the year "1958". At the very bottom of the page, there is a small navigation bar with several icons: a square, a circle, a triangle, and a set of three horizontal lines, likely for navigating through the presentation slides.

- 随机裁剪+缩放至原大小
- 随机颜色失真（关键增强）
- 随机高斯模糊

- **随机数据增强模块**
 - 随机裁剪+缩放至原大小
 - 随机颜色失真（关键增强）
 - 随机高斯模糊
- **基础编码网络（Encoder）**
 - 通常使用 ResNet-50
 - 输出 2048 维特征向量 h

- **投影头 (Projection Head)**
 - 两层 MLP (FC-BN-ReLU-FC)
 - 将特征映射到对比空间 z

- **随机数据增强模块**
 - 随机裁剪+缩放至原大小
 - 随机颜色失真 (关键增强)
 - 随机高斯模糊
- **基础编码网络 (Encoder)**
 - 通常使用 ResNet-50
 - 输出 2048 维特征向量 h
- **投影头 (Projection Head)**
 - 两层 MLP (FC-BN-ReLU-FC)
 - 将特征映射到对比空间 z

- **投影头 (Projection Head)**
 - 两层 MLP (FC-BN-ReLU-FC)
 - 将特征映射到对比空间 z
- **对比损失函数 (NT-Xent)**
 - 归一化温度缩放交叉熵损失
 - 温度参数 τ 控制分布集中度

- **随机数据增强模块**
 - 随机裁剪+缩放至原大小
 - 随机颜色失真 (关键增强)
 - 随机高斯模糊
- **基础编码网络 (Encoder)**
 - 通常使用 ResNet-50
 - 输出 2048 维特征向量 h
- **投影头 (Projection Head)**
 - 两层 MLP (FC-BN-ReLU-FC)
 - 将特征映射到对比空间 z
- **对比损失函数 (NT-Xent)**
 - 归一化温度缩放交叉熵损失
 - 温度参数 τ 控制分布集中度

- **投影头 (Projection Head)**
 - 两层 MLP (FC-BN-ReLU-FC)
 - 将特征映射到对比空间 z
- **对比损失函数 (NT-Xent)**
 - 归一化温度缩放交叉熵损失
 - 温度参数 τ 控制分布集中度

- **随机数据增强模块**
 - 随机裁剪+缩放至原大小
 - 随机颜色失真 (关键增强)
 - 随机高斯模糊
- **基础编码网络 (Encoder)**
 - 通常使用 ResNet-50
 - 输出 2048 维特征向量 h
- **投影头 (Projection Head)**
 - 两层 MLP (FC-BN-ReLU-FC)
 - 将特征映射到对比空间 z
- **对比损失函数 (NT-Xent)**
 - 归一化温度缩放交叉熵损失
 - 温度参数 τ 控制分布集中度

关键创新点

通过系统实验发现：**数据增强组合 + 非线性投影头**是提升性能的关键

（尤其裁剪+颜色失真）显著提升表征质量
增强数据增强

- **数据增强的重要性**
 - 单一增强效果有限，组合增强（尤其裁剪+颜色失真）显著提升表征质量
 - 对比学习比监督学习更受益于强数据增强

(尤其裁剪+颜色失真) 显著提升表征质量
强数据增强

直接使用编码器特征效果提升约 10%
用编码器特征用于下游任务

- **数据增强的重要性**
 - 单一增强效果有限，组合增强（尤其裁剪+颜色失真）显著提升表征质量
 - 对比学习比监督学习更受益于强数据增强
- **投影头的作用**
 - 使用非线性投影头（MLP）比直接使用编码器特征效果提升约 10%
 - 训练完成后丢弃投影头，仅使用编码器特征用于下游任务

(尤其裁剪+颜色失真) 显著提升表征质量
强数据增强

直接使用编码器特征效果提升约 10%
用编码器特征用于下游任务

$$\frac{\exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_j)/\tau)}{\sum_{k=1}^{2N} \mathbf{1}_{[k \neq i]} \exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_k)/\tau)}$$

个增强样本

- (尤其裁剪+颜色失真) 显著提升表征质量
强数据增强
- 直接使用编码器特征效果提升约 10%
用编码器特征用于下游任务
- $$\frac{\exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_j)/\tau)}{\sum_{k=1}^{2N} \mathbf{1}_{[k \neq i]} \exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_k)/\tau)}$$
- 个增强样本

(尤其裁剪+颜色失真) 显著提升表征质量
强数据增强

直接使用编码器特征效果提升约 10%
用编码器特征用于下游任务

$$\frac{\exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_j)/\tau)}{\sum_{k=1}^{2N} \mathbf{1}_{[k \neq i]} \exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_k)/\tau)}$$

个增强样本

(尤其裁剪+颜色失真) 显著提升表征质量
强数据增强


直接使用编码器特征效果提升约 10%
用编码器特征用于下游任务

$$\frac{\exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_j)/\tau)}{\sum_{k=1}^{2N} \mathbf{1}_{[k \neq i]} \exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_k)/\tau)}$$

个增强样本

- **大批次训练**

- 使用极大批次 (最多 8192) 提供充足负样本
- 采用 LARS 优化器解决大批次训练不稳定问题



批次大小对性能的影响

供充足负


训练不稳定

的 BN 统

批次大小对性能的影响

Batch Size	Accuracy
256	81.92
8192	81.92

- **大批次训练**
 - 使用极大批次（最多 8192）提供充足负样本
 - 采用 LARS 优化器解决大批次训练不稳定性问题
- **全局批归一化（Global BN）**
 - 在多 GPU 训练中聚合所有设备的 BN 统计量
 - 防止正样本对间的信息泄露




批次大小对性能的影响

- 使用极大批次（最多 8192）提供充足负样本
- 采用 LARS 优化器解决大批次训练不稳定性问题

- 在多 GPU 训练中聚合所有设备的 BN 统计量
- 防止正样本对间的信息泄露

- Linear Evaluation: 76.5% Top-1 (ImageNet)
- 仅用 1% 标签微调: 85.8% Top-5
- 超越同期 MoCo v1, 推动对比学习发展



批次大小对性能的影响

提供充足负

训练不稳定

性能提升

256

8192


Batch Size

批次大小对性能的影响

- 使用极大批次 (最多 8192) 提供充足负样本
- 采用 LARS 优化器解决大批次训练不稳定问题

- 在多 GPU 训练中聚合所有设备的 BN 统计量
- 防止正样本对间的信息泄露

- Linear Evaluation: 76.5% Top-1 (ImageNet)
- 仅用 1% 标签微调: 85.8% Top-5
- 超越同期 MoCo v1, 推动对比学习发展



奠定了对比学习标准架构，系统分析了各组件影响，为后续研究 (MoCo v2/v3、BYOL 等) 奠定基础

- 核心改进：**整合 SimCLR 的两个关键创新


```

graph TD
    A([随机裁剪]) --> D[Backbone (ResNet)]
    B([色彩抖动]) --> D
    C([高斯模糊]) --> D
    D --> E[Projection Head (MLP)]
    E --> F[对比空间]
      
```

-
- ```
graph TD; A([随机裁剪]) --> D[Backbone (ResNet)]; B([色彩抖动]) --> D; C([高斯模糊]) --> D; D --> E[Projection Head (MLP)]; E --> F[对比空间];
```

- **核心改进：**整合 SimCLR 的两个关键创新
- **MLP Projection Head：**

```

graph TD
 A([随机裁剪]) --> D[Backbone (ResNet)]
 B([色彩抖动]) --> D
 C([高斯模糊]) --> D
 D --> E[Projection Head (MLP)]
 E --> F[对比空间]

```

The diagram illustrates the SimCLR architecture. It starts with three input images at the top, each with a different augmentation: '随机裁剪' (Random Crop), '色彩抖动' (Color Jitter), and '高斯模糊' (Gaussian Blur). These images are processed by a 'Backbone (ResNet)' block. The output of the backbone is then passed through a 'Projection Head (MLP)' block. Finally, the output is mapped into a '对比空间' (Contrastive Space).

- 
- ```
graph TD; A([随机裁剪]) --> D[Backbone (ResNet)]; B([色彩抖动]) --> D; C([高斯模糊]) --> D; D --> E[Projection Head (MLP)]; E --> F[对比空间];
```

- **核心改进：**整合 SimCLR 的两个关键创新
- **MLP Projection Head：**
 - 替换单层 FC 为两层 MLP

```

graph TD
    A([随机裁剪]) --> D[Backbone (ResNet)]
    B([色彩抖动]) --> D
    C([高斯模糊]) --> D
    D --> E[Projection Head (MLP)]
    E --> F[对比空间]
  
```

-
- ```
graph TD; A([随机裁剪]) --> D[Backbone (ResNet)]; B([色彩抖动]) --> D; C([高斯模糊]) --> D; D --> E[Projection Head (MLP)]; E --> F[对比空间];
```



- **核心改进：**整合 SimCLR 的两个关键创新
- **MLP Projection Head：**
  - 替换单层 FC 为两层 MLP
  - 隐藏层维度 2048→128

```

graph TD
 A([随机裁剪]) --> D[Backbone ResNet]
 B([色彩抖动]) --> D
 C([高斯模糊]) --> D
 D --> E[Projection Head MLP]
 E --> F[对比空间]

```

- 
- ```
graph TD; A([随机裁剪]) --> D[Backbone (ResNet)]; B([色彩抖动]) --> D; C([高斯模糊]) --> D; D --> E[Projection Head (MLP)]; E --> F[对比空间];
```

- **核心改进：**整合 SimCLR 的两个关键创新
- **MLP Projection Head：**
 - 替换单层 FC 为两层 MLP
 - 隐藏层维度 2048→128
 - 训练后丢弃，仅保留编码器

```

graph TD
    A([随机裁剪]) --> D[Backbone (ResNet)]
    B([色彩抖动]) --> D
    C([高斯模糊]) --> D
    D --> E[Projection Head (MLP)]
    E --> F[对比空间]
  
```

-
- ```

graph TD
 A([随机裁剪]) --> D[Backbone (ResNet)]
 B([色彩抖动]) --> D
 C([高斯模糊]) --> D
 D --> E[Projection Head (MLP)]
 E --> F[对比空间]

```

- **核心改进：**整合 SimCLR 的两个关键创新
- **MLP Projection Head：**
  - 替换单层 FC 为两层 MLP
  - 隐藏层维度 2048→128
  - 训练后丢弃，仅保留编码器
- **增强数据增强：**

```

graph TD
 A([随机裁剪]) --> D[Backbone (ResNet)]
 B([色彩抖动]) --> D
 C([高斯模糊]) --> D
 D --> E[Projection Head (MLP)]
 E --> F[对比空间]

```

- 
- ```
graph TD; A([随机裁剪]) --> D[Backbone (ResNet)]; B([色彩抖动]) --> D; C([高斯模糊]) --> D; D --> E[Projection Head (MLP)]; E --> F[对比空间];
```

- **核心改进：**整合 SimCLR 的两个关键创新
- **MLP Projection Head：**
 - 替换单层 FC 为两层 MLP
 - 隐藏层维度 2048→128
 - 训练后丢弃，仅保留编码器
- **增强数据增强：**
 - 添加高斯模糊增强

```

graph TD
    A([随机裁剪]) --> D[Backbone ResNet]
    B([色彩抖动]) --> D
    C([高斯模糊]) --> D
    D --> E[Projection Head MLP]
    E --> F[对比空间]
  
```

-
- ```

graph TD
 A([随机裁剪]) --> D[Backbone (ResNet)]
 B([色彩抖动]) --> D
 C([高斯模糊]) --> D
 D --> E[Projection Head (MLP)]
 E --> F[对比空间]

```
- Diagram illustrating the proposed network architecture:
- Input features: 随机裁剪 (Random Cropping), 色彩抖动 (Color Jitter), 高斯模糊 (Gaussian Blur).
  - These features are processed by the **Backbone (ResNet)**.
  - The output of the backbone is fed into the **Projection Head (MLP)**.
  - The final output is the **对比空间** (Contrast Space).

- **核心改进：**整合 SimCLR 的两个关键创新
- **MLP Projection Head：**
  - 替换单层 FC 为两层 MLP
  - 隐藏层维度 2048→128
  - 训练后丢弃，仅保留编码器
- **增强数据增强：**
  - 添加高斯模糊增强
  - 扩展色彩抖动范围

```

graph TD
 A([随机裁剪]) --> D[Backbone (ResNet)]
 B([色彩抖动]) --> D
 C([高斯模糊]) --> D
 D --> E[Projection Head (MLP)]
 E --> F[对比空间]

```

- 
- ```

graph TD
    A([随机裁剪]) --> D[Backbone (ResNet)]
    B([色彩抖动]) --> D
    C([高斯模糊]) --> D
    D --> E[Projection Head (MLP)]
    E --> F[对比空间]
  
```
- Diagram illustrating the proposed network architecture:
- Three input modules (Random Cropping, Color Jitter, Gaussian Blur) feed into the Backbone (ResNet).
 - The Backbone (ResNet) output feeds into the Projection Head (MLP).
 - The Projection Head (MLP) output feeds into the Contrast Space.

- **核心改进：**整合 SimCLR 的两个关键创新
- **MLP Projection Head：**
 - 替换单层 FC 为两层 MLP
 - 隐藏层维度 2048→128
 - 训练后丢弃，仅保留编码器
- **增强数据增强：**
 - 添加高斯模糊增强
 - 扩展色彩抖动范围
 - 提升正样本质量

```

graph TD
    A([随机裁剪]) --> D[Backbone ResNet]
    B([色彩抖动]) --> D
    C([高斯模糊]) --> D
    D --> E[Projection Head MLP]
    E --> F[对比空间]
  
```

-
- ```

graph TD
 A([随机裁剪]) --> D[Backbone (ResNet)]
 B([色彩抖动]) --> D
 C([高斯模糊]) --> D
 D --> E[Projection Head (MLP)]
 E --> F[对比空间]

```
- Diagram illustrating the proposed network architecture:
- Input features: 随机裁剪 (Random Cropping), 色彩抖动 (Color Jitter), 高斯模糊 (Gaussian Blur).
  - These features are processed by the **Backbone (ResNet)**.
  - The output of the backbone is fed into the **Projection Head (MLP)**.
  - The final output is the **对比空间** (Contrast Space).

Latent (引导你自己的潜在表示)

- A set of small navigation icons typically found in Beamer presentations, including symbols for back, forward, search, and other slide controls.

Latent (引导你自己的潜在表示)

提出, 突破传统对比学习的负样本依赖

- **模型全称**: Bootstrap Your Own Latent (引导你自己的潜在表示)
- **提出背景**: DeepMind 于 2020 年提出, 突破传统对比学习的负样本依赖



Latent (引导你自己的潜在表示)

提出, 突破传统对比学习的负样本依赖训练, 无需显式构造负样本

- **模型全称**: Bootstrap Your Own Latent (引导你自己的潜在表示)
- **提出背景**: DeepMind 于 2020 年提出, 突破传统对比学习的负样本依赖
- **核心创新**: 仅使用正样本对进行训练, 无需显式构造负样本

Latent (引导你自己的潜在表示)

提出, 突破传统对比学习的负样本依赖训练, 无需显式构造负样本

架构, 可避免模型塌缩问题

- **模型全称**: Bootstrap Your Own Latent (引导你自己的潜在表示)
- **提出背景**: DeepMind 于 2020 年提出, 突破传统对比学习的负样本依赖
- **核心创新**: 仅使用正样本对进行训练, 无需显式构造负样本
- **关键发现**: 通过精心设计的学习架构, 可避免模型塌缩问题

latent (引导你自己的潜在表示)


提出，突破传统对比学习的负样本依赖训练，无需显式构造负样本

架构，可避免模型塌缩问题

4.3%的 Top-1 准确率，接近有监督学习


- **模型全称**: Bootstrap Your Own Latent (引导你自己的潜在表示)
- **提出背景**: DeepMind 于 2020 年提出, 突破传统对比学习的负样本依赖
- **核心创新**: 仅使用正样本对进行训练, 无需显式构造负样本
- **关键发现**: 通过精心设计的学习架构, 可避免模型塌缩问题
- **突出成果**: 在 ImageNet 上达到 74.3% 的 Top-1 准确率, 接近有监督学习

- **双分支设计:**



## BYOL 架构示意图

- **在线网络 (Online Network): 通过梯度更新**




## BYOL 架构示意图

- **双分支设计:**
  - **在线网络 (Online Network):** 通过梯度更新
  - **目标网络 (Target Network):** 动量更新

The diagram illustrates the BYOL architecture. It features two parallel processing paths. The top path, labeled '在线网络' (Online Network) in blue, starts with an input  $x$  passing through an '增强' (Augmentation) block. The output then splits into two branches: one through a function block  $f_\theta$  and another through  $f_\xi$ . The  $f_\theta$  branch continues through two more blocks,  $g_\theta$  and  $q_\theta$ , all connected by blue arrows. The  $f_\xi$  branch continues through a block  $g_\xi$ , connected by a red arrow. Both paths converge at a final block  $L_\theta$ , which represents the loss function. The entire structure is labeled 'BYOL 架构示意图' (BYOL Architecture Schematic Diagram) at the bottom.

- ## 在线网络

## 目标网络



## BYOL 架构示意图

- **双分支设计:**
  - **在线网络** (Online Network): 通过梯度更新
  - **目标网络** (Target Network): 动量更新
- **网络组成:**




The diagram illustrates the BYOL architecture. At the top, an input  $x$  is processed by an '增强' (augmentation) block. This leads to two parallel branches: the '在线网络' (Online Network) in blue and the '目标网络' (Target Network) in red. The Online Network consists of feature extractor  $f_\theta$ , gradient calculator  $g_\theta$ , and quantizer  $q_\theta$ . The Target Network consists of feature extractor  $f_\xi$  and gradient calculator  $g_\xi$ . The outputs of the Online Network's quantizer and the Target Network's gradient calculator are fed into a loss function  $L_\theta$ .

BYOL 架构示意图

- ## 在线网络


## 目标网络



## BYOL 架构示意图

- **双分支设计:**
  - **在线网络** (Online Network): 通过梯度更新
  - **目标网络** (Target Network): 动量更新
- **网络组成:**
  - 编码器  $f_\theta$ : 提取特征  $h$


BYOL 架构示意图





- **双分支设计:**
  - **在线网络** (Online Network): 通过梯度更新
  - **目标网络** (Target Network): 动量更新
- **网络组成:**
  - 编码器  $f_\theta$ : 提取特征  $\mathbf{h}$
  - 投影头  $g_\theta$ : 映射到投影空间  $\mathbf{z}$

BYOL 架构示意图




## BYOL 架构示意图

- **双分支设计:**
  - **在线网络 (Online Network):** 通过梯度更新
  - **目标网络 (Target Network):** 动量更新
- **网络组成:**
  - 编码器  $f_\theta$ : 提取特征  $\mathbf{h}$
  - 投影头  $g_\theta$ : 映射到投影空间  $\mathbf{z}$
  - 预测头  $q_\theta$ : 仅在线网络独有



The diagram illustrates the BYOL architecture. It features two parallel processing paths: an 'Online Network' (left, blue) and a 'Target Network' (right, red). Both paths start with an input 'x' that passes through an 'enhancement' step (x 增强). The Online path consists of an encoder  $f_\theta$ , a projection head  $g_\theta$ , and a prediction head  $q_\theta$ . The Target path consists of an encoder  $f_\xi$  and a projection head  $g_\xi$ . The output of the Online prediction head  $q_\theta$  and the output of the Target projection head  $g_\xi$  are compared at a loss module  $L_\theta$  to calculate the loss.




## BYOL 架构示意图

- **双分支设计:**
  - **在线网络** (Online Network): 通过梯度更新
  - **目标网络** (Target Network): 动量更新
- **网络组成:**
  - 编码器  $f_\theta$ : 提取特征  $\mathbf{h}$
  - 投影头  $g_\theta$ : 映射到投影空间  $\mathbf{z}$
  - 预测头  $q_\theta$ : 仅在线网络独有
- **训练目标:**




BYOL 架构示意图



- **双分支设计:**
  - **在线网络 (Online Network):** 通过梯度更新
  - **目标网络 (Target Network):** 动量更新
- **网络组成:**
  - 编码器  $f_\theta$ : 提取特征  $h$
  - 投影头  $g_\theta$ : 映射到投影空间  $z$
  - 预测头  $q_\theta$ : 仅在线网络独有
- **训练目标:**
  - 在线网络预测目标网络的输出


The diagram illustrates the BYOL (Bootstrap Your Own Latent) architecture. It consists of two parallel branches: the Online Network (left, blue) and the Target Network (right, red). Both branches start with a shared input  $x$  that is augmented ( $x$  增强). The Online Network contains an encoder  $f_\theta$ , a projection head  $g_\theta$ , and a prediction head  $q_\theta$ . The Target Network contains an encoder  $f_\xi$  and a projection head  $g_\xi$ . The output of the prediction head  $q_\theta$  is compared with the output of the projection head  $g_\xi$  using a loss function  $L_\theta$  to calculate the training loss.



## BYOL 架构示意图

- **双分支设计:**
  - **在线网络 (Online Network):** 通过梯度更新
  - **目标网络 (Target Network):** 动量更新
- **网络组成:**
  - 编码器  $f_\theta$ : 提取特征  $h$
  - 投影头  $g_\theta$ : 映射到投影空间  $z$
  - 预测头  $q_\theta$ : 仅在线网络独有
- **训练目标:**
  - 在线网络预测目标网络的输出
  - 最小化预测值与目标值的均方误差

The diagram illustrates the BYOL architecture. It starts with an input  $x$  passing through an '增强' (augmentation) process. This leads to two parallel branches: the '在线网络' (Online Network) in blue and the '目标网络' (Target Network) in red. The Online Network consists of an encoder  $f_\theta$ , a projection head  $g_\theta$ , and a prediction head  $q_\theta$ . The Target Network consists of an encoder  $f_\xi$  and a projection head  $g_\xi$ . The output of the Online Network's prediction head  $q_\theta$  is compared with the output of the Target Network's projection head  $g_\xi$  using a loss function  $L_\theta$ .



- **非对称网络结构**



A large, faint watermark of the Fuzhou University logo is centered on the page. The logo is circular, featuring the university's name in English, "FUZHOU UNIVERSITY", around the top and the Chinese characters "福州大学" around the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú), which means "blessing" or "good fortune". Below the character "福" is the year "1958". At the very bottom of the page, there is a small navigation bar with several icons: a square, a circle, a triangle, and a set of three horizontal lines, likely representing different views or functions of the presentation software.

- A set of small navigation icons typically found in Beamer presentations, including symbols for back, forward, search, and other slide controls.

A large, faint watermark of the Fuzhou University logo is centered on the page. The logo is circular, featuring the university's name in English, "FUZHOU UNIVERSITY", around the top and the Chinese characters "福州大学" around the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú), which means "blessing" or "good fortune". Below the character "福" is the year "1958". At the very bottom of the page, there is a small navigation bar with several icons: a square, a circle, a triangle, and a set of three horizontal lines, likely representing different views or functions of the presentation software.

- **非对称网络结构**
  - 目标网络缺少预测头  $q_\theta$
  - 打破网络对称性



A large, faint watermark of the Fuzhou University logo is centered on the page. The logo is circular, featuring the university's name in English, "FUZHOU UNIVERSITY", around the top and the Chinese characters "福州大学" around the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú), which is a common symbol for good fortune. Below the character "福" is the year "1958", indicating the university's founding year.

- 目标网络缺少预测头  $q_\theta$
- 打破网络对称性
- 防止平凡解（所有特征相同）

-

A large, faint watermark of the Fuzhou University logo is centered on the page. The logo is circular, with the English text 'FUZHOU UNIVERSITY' around the top and '福州' (Fuzhou) in Chinese characters around the bottom. In the center of the logo is a large white character '福' (Fú), which means 'blessing' or 'good fortune'. Below the character '福' is the year '1958'.

-



- 目标网络缺少预测头  $q_\theta$
- 打破网络对称性
- 防止平凡解 (所有特征相同)

- 目标网络:  $\xi \leftarrow \tau\xi + (1 - \tau)\theta$
- 目标网络不反向传播梯度
- 保持特征表示的稳定性

- **动量编码器更新**

$$\xi \leftarrow \tau \xi + (1 - \tau) \theta$$

其中：

- **非对称网络结构**
  - 目标网络缺少预测头  $q_\theta$
  - 打破网络对称性
  - 防止平凡解（所有特征相同）
- **停止梯度（Stop-Gradient）**
  - 目标网络： $\xi \leftarrow \tau \xi + (1 - \tau)\theta$
  - 目标网络不反向传播梯度
  - 保持特征表示的稳定性

## ● 动量编码器更新

$$\xi \leftarrow \tau \xi + (1 - \tau) \theta$$

其中：

- $\tau \approx 0.996$  (接近 1)

- **非对称网络结构**
  - 目标网络缺少预测头  $q_\theta$
  - 打破网络对称性
  - 防止平凡解（所有特征相同）
- **停止梯度（Stop-Gradient）**
  - 目标网络： $\xi \leftarrow \tau \xi + (1 - \tau)\theta$
  - 目标网络不反向传播梯度
  - 保持特征表示的稳定性

## ● 动量编码器更新

$$\xi \leftarrow \tau \xi + (1 - \tau)\theta$$

其中：

- **非对称网络结构**
  - 目标网络缺少预测头  $q_\theta$
  - 打破网络对称性
  - 防止平凡解（所有特征相同）
- **停止梯度（Stop-Gradient）**
  - 目标网络： $\xi \leftarrow \tau \xi + (1 - \tau)\theta$
  - 目标网络不反向传播梯度
  - 保持特征表示的稳定性

- $\tau \approx 0.996$  (接近 1)
- 目标网络缓慢跟随在线网络



## ● 动量编码器更新

$$\xi \leftarrow \tau \xi + (1 - \tau) \theta$$


其中：

- **非对称网络结构**
  - 目标网络缺少预测头  $q_\theta$
  - 打破网络对称性
  - 防止平凡解（所有特征相同）
- **停止梯度（Stop-Gradient）**
  - 目标网络： $\xi \leftarrow \tau \xi + (1 - \tau)\theta$
  - 目标网络不反向传播梯度
  - 保持特征表示的稳定性

- $\tau \approx 0.996$  (接近 1)
- 目标网络缓慢跟随在线网络
- 避免快速变化的特征表示

---

- **理论突破**




## 简化趋势

## BYOL 在自监督学习中的位置


\_\_\_\_\_

- © 2015 Blackwell Publishing Ltd *Journal of Internal Medicine* 258: 1–12



## BYOL 在自监督学习中的位置

- 证明无需负样本也能避免模型塌缩
- 打破“对比学习需要负样本”的固有观念



## 简化趋势

## BYOL 在自监督学习中的位置

易缩  
固有观念

```
graph TD; MoCo((MoCo)) --> BYOL((BYOL)); SimCLR((SimCLR)) --> BYOL; BYOL --> SimSiam((SimSiam))
```

简化趋势

BYOL 在自监督学习中的位置

- A set of small navigation icons typically found in Beamer presentations, including symbols for back, forward, search, and other slide controls.

- **理论突破**
  - 证明无需负样本也能避免模型塌缩
  - 打破“对比学习需要负样本”的固有观念
  - 为后续研究提供新的理论方向
- **实际优势**



```
graph TD; MoCo((MoCo)) --> BYOL((BYOL)); SimCLR((SimCLR)) --> BYOL; BYOL --> SimSiam((SimSiam))
```

简化趋势

BYOL 在自监督学习中的位置



## BYOL 在自监督学习中的位置

- **理论突破**
  - 证明无需负样本也能避免模型塌缩
  - 打破“对比学习需要负样本”的固有观念
  - 为后续研究提供新的理论方向
- **实际优势**
  - 减少对大批次训练的依赖

```
graph TD; MoCo((MoCo)) --> BYOL((BYOL)); SimCLR((SimCLR)) --> BYOL; BYOL --> SimSiam((SimSiam))
```

简化趋势

BYOL 在自监督学习中的位置



## BYOL 在自监督学习中的位置



- **理论突破**
  - 证明无需负样本也能避免模型塌缩
  - 打破“对比学习需要负样本”的固有观念
  - 为后续研究提供新的理论方向
- **实际优势**
  - 减少对大批次训练的依赖
  - 降低 GPU 内存需求

```
graph TD; MoCo((MoCo)) --> BYOL((BYOL)); SimCLR((SimCLR)) --> BYOL; BYOL --> SimSiam((SimSiam))
```

简化趋势


BYOL 在自监督学习中的位置



## BYOL 在自监督学习中的位置

- 证明无需负样本也能避免模型塌缩
- 打破“对比学习需要负样本”的固有观念
- 为后续研究提供新的理论方向

- 减少对大批次训练的依赖
- 降低 GPU 内存需求
- 对小规模数据集更友好



## 简化趋势

## BYOL 在自监督学习中的位置

- **理论突破**
  - 证明无需负样本也能避免模型塌缩
  - 打破“对比学习需要负样本”的固有观念
  - 为后续研究提供新的理论方向
- **实际优势**
  - 减少对大批次训练的依赖
  - 降低 GPU 内存需求
  - 对小规模数据集更友好
- **后续影响**

```
graph TD; MoCo((MoCo)) --> BYOL((BYOL)); SimCLR((SimCLR)) --> BYOL; BYOL --> SimSiam((SimSiam))
```

简化趋势

BYOL 在自监督学习中的位置



## BYOL 在自监督学习中的位置

易缩  
固有观念

```
graph TD; MoCo((MoCo)) --> BYOL((BYOL)); SimCLR((SimCLR)) --> BYOL; BYOL --> SimSiam((SimSiam))
```

简化趋势

BYOL 在自监督学习中的位置

- ## 简化趋势

## BYOL 在自监督学习中的位置

- **理论突破**
  - 证明无需负样本也能避免模型塌缩
  - 打破“对比学习需要负样本”的固有观念
  - 为后续研究提供新的理论方向
- **实际优势**
  - 减少对大批次训练的依赖
  - 降低 GPU 内存需求
  - 对小规模数据集更友好
- **后续影响**
  - 启发了 SimSiam 等简化模型
  - 推动自监督学习向更简洁方向发展

```
graph TD; MoCo((MoCo)) --> BYOL((BYOL)); SimCLR((SimCLR)) --> BYOL; BYOL --> SimSiam((SimSiam));
```

简化趋势


BYOL 在自监督学习中的位置



## BYOL 在自监督学习中的位置

## BYOL 的技术创新与影响

- **理论突破**
  - 证明无需负样本也能避免模型塌缩
  - 打破“对比学习需要负样本”的固有观念
  - 为后续研究提供新的理论方向
- **实际优势**
  - 减少对大批次训练的依赖
  - 降低 GPU 内存需求
  - 对小规模数据集更友好
- **后续影响**
  - 启发了 SimSiam 等简化模型
  - 推动自监督学习向更简洁方向发展
  - 在视频、多模态等领域广泛应用



## 简化趋势

## BYOL 在自监督学习中的位置

## 主流对比学习方法对比 (ImageNet Top-1)

| 特性    | MoCo v2       | SimCLR    | BYOL          |
|-------|---------------|-----------|---------------|
| 负样本需求 | 需要 (队列)       | 需要 (批次内)  | 不需要           |
| 批次大小  | 中等 (256-1024) | 极大 (8192) | 中等 (256-1024) |
| 内存需求  | 中等            | 极高        | 中等            |
| 核心机制  | 动量编码器+队列      | 强数据增强     | 非对称网络+动量更新    |
| 训练稳定性 | 高             | 中等        | 高             |
| 理论复杂性 | 中等            | 中等        | 高 (无负样本)      |
| 性能表现  | 71.1%         | 69.3%     | 74.3%         |

## BYOL 的局限性

- **训练不稳定**: 需要仔细调整超参数 ( $\tau$  值、学习率等)
- **对 BatchNorm 敏感**: 大规模分布式训练中需要特殊处理

mer 架构

- A set of small navigation icons typically found in Beamer presentations, including symbols for back, forward, search, and other slide controls.



mer 架构

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ◀ ↺ 🔍 ↻

mer 架构

负样本

- mer 架构
- 负样本

mer 架构

负样本

- mer 架构
- 负样本

mer 架构

负样本

- mer 架构
- 负样本

mer 架构

负样本

- **核心创新：**适配 Vision Transformer 架构
- **移除内存队列：**
  - 使用大批次（4096）提供足够负样本
  - 简化系统复杂度
  - 更适合 ViT 特性
- **对称对比损失：**

mer 架构

负样本

失

- mer 架构
- 负样本
- 失

mer 架构

负样本

失

- mer 架构
- 负样本
- 失

mer 架构

负样本

失

- **核心创新：**适配 Vision Transformer 架构
- **移除内存队列：**
  - 使用大批次（4096）提供足够负样本
  - 简化系统复杂度
  - 更适合 ViT 特性
- **对称对比损失：**
  - 同时计算  $q_1 \rightarrow k_2$  和  $q_2 \rightarrow k_1$  损失
  - 提升训练效率和稳定性
- **预测头增强：**



mer 架构

负样本

失

- mer 架构
- 负样本
- 失

mer 架构


负样本

失

- mer 架构
- 负样本
- 失



- **发现关键问题：ViT 训练不稳定性**
  - 训练曲线出现"dip"现象



## 训练稳定性对比

生

精度 (%)

训练步数

— 稳定训练

— 不稳定训练

训练稳定性对比

| 训练步数 | 稳定训练精度 (%) | 不稳定训练精度 (%) |
|------|------------|-------------|
| 0    | 72.0       | 70.0        |
| 200  | 73.5       | 73.5        |
| 400  | 74.5       | 74.8        |
| 600  | 75.0       | 75.0        |
| 800  | 75.0       | 75.0        |
| 1000 | 75.0       | 75.0        |

- 
- The graph illustrates the convergence of accuracy over training steps for two different training conditions. The y-axis represents accuracy in percentage, ranging from 70 to 74. The x-axis represents training steps, ranging from 0 to 1,000. The blue line, labeled '稳定训练' (Stable Training), starts at approximately 72% accuracy at step 0 and increases steadily to about 75% by step 1,000. The red line, labeled '不稳定训练' (Unstable Training), starts at approximately 70% accuracy at step 0, rises more steeply than the blue line, and also converges to about 75% accuracy by step 1,000.
- | 训练步数  | 稳定训练 (精度 %) | 不稳定训练 (精度 %) |
|-------|-------------|--------------|
| 0     | 72.0        | 70.0         |
| 200   | 74.0        | 74.0         |
| 400   | 74.8        | 75.0         |
| 600   | 75.0        | 75.2         |
| 800   | 75.1        | 75.2         |
| 1,000 | 75.1        | 75.2         |

## 训练稳定性对比

生

精度 (%)

74

72

70

0 200 400 600 800 1,000

训练步数

— 稳定训练

— 不稳定训练

训练稳定性对比

- A set of small navigation icons typically found in Beamer presentations, including symbols for back, forward, search, and other slide controls.

生

精度 (%)

训练步数

— 稳定训练

— 不稳定训练

训练稳定性对比

| 训练步数 | 稳定训练精度 (%) | 不稳定训练精度 (%) |
|------|------------|-------------|
| 0    | 72.0       | 70.0        |
| 200  | 74.0       | 74.0        |
| 400  | 74.8       | 75.0        |
| 600  | 75.0       | 75.0        |
| 800  | 75.0       | 75.0        |
| 1000 | 75.0       | 75.0        |

- 
- The graph shows the accuracy of two training methods over 1,000 steps. The 'Stable Training' method (blue line) starts at 72% accuracy at step 0 and increases steadily to approximately 78.5% by step 1,000. The 'Unstable Training' method (red line) starts at 70% accuracy at step 0, rises more steeply initially, crosses the stable method at step 200, and eventually reaches the same plateau of approximately 78.5% by step 1,000.
- | 训练步数  | 稳定训练精度 (%) | 不稳定训练精度 (%) |
|-------|------------|-------------|
| 0     | 72.0       | 70.0        |
| 200   | 74.0       | 74.0        |
| 400   | 75.5       | 75.5        |
| 600   | 77.5       | 77.5        |
| 800   | 78.2       | 78.2        |
| 1,000 | 78.5       | 78.5        |

## 训练稳定性对比

生

精度 (%)

74

72

70

0 200 400 600 800 1,000

训练步数

— 稳定训练

— 不稳定训练

训练稳定性对比

- 
- The graph shows the accuracy (%) of two training methods over 1,000 training steps. The 'Stable Training' method (blue line) starts at approximately 72% accuracy at step 0 and increases steadily to about 75.5% by step 1,000. The 'Unstable Training' method (red line) starts at 70% accuracy at step 0, rises more steeply than the stable method, and eventually reaches the same plateau of approximately 75.5% accuracy by step 1,000. A legend at the bottom identifies the two series: '稳定训练' (Stable Training) in blue and '不稳定训练' (Unstable Training) in red.
- | 训练步数  | 稳定训练 (%) | 不稳定训练 (%) |
|-------|----------|-----------|
| 0     | 72.0     | 70.0      |
| 200   | 74.0     | 74.0      |
| 400   | 75.0     | 75.0      |
| 600   | 75.4     | 75.4      |
| 800   | 75.5     | 75.5      |
| 1,000 | 75.5     | 75.5      |

## 训练稳定性对比



生

精度 (%)

74

72

70

0 200 400 600 800 1,000

训练步数

— 稳定训练

— 不稳定训练

训练稳定性对比

- 
- The graph illustrates the accuracy of two training methods over 1,000 steps. The 'Stable Training' method (blue line) starts at approximately 72.0% accuracy at step 0 and increases steadily to about 75.2% by step 1,000. The 'Unstable Training' method (red line) starts at a lower accuracy of approximately 70.0% at step 0, rises more steeply, and eventually surpasses the stable method around step 400, reaching the same plateau of approximately 75.2% by step 1,000.
- | 训练步数  | 稳定训练 (精度 %) | 不稳定训练 (精度 %) |
|-------|-------------|--------------|
| 0     | 72.0        | 70.0         |
| 200   | 74.0        | 73.5         |
| 400   | 74.8        | 75.0         |
| 600   | 75.1        | 75.2         |
| 800   | 75.2        | 75.2         |
| 1,000 | 75.2        | 75.2         |

## 训练稳定性对比

生

精度 (%)

74

72

70

0 200 400 600 800 1,000

训练步数

— 稳定训练

— 不稳定训练

训练稳定性对比

- 
- 精度 (%)
- 训练步数
- 稳定训练
- 不稳定训练
- | 训练步数  | 稳定训练精度 (%) | 不稳定训练精度 (%) |
|-------|------------|-------------|
| 0     | 72.0       | 70.0        |
| 200   | 74.0       | 74.0        |
| 400   | 75.5       | 76.0        |
| 600   | 77.0       | 77.5        |
| 800   | 77.5       | 77.8        |
| 1,000 | 77.8       | 77.8        |

## 训练稳定性对比

生

精度 (%)

74

72

70

0 200 400 600 800 1,000

训练步数

— 稳定训练

— 不稳定训练

训练稳定性对比

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ↺ 🔍 ↻

训练稳定性对比

| 训练步数  | 稳定训练精度 (%) | 不稳定训练精度 (%) |
|-------|------------|-------------|
| 0     | 72.0       | 70.0        |
| 200   | 73.5       | 73.0        |
| 400   | 74.5       | 74.5        |
| 600   | 75.0       | 75.0        |
| 800   | 75.0       | 75.0        |
| 1,000 | 75.0       | 75.0        |

- 
- The graph illustrates the accuracy of two training methods over 1,000 steps. The 'Stable Training' method (blue line) starts at approximately 72% accuracy and reaches a plateau of about 75.5% by 1,000 steps. The 'Unstable Training' method (red line) starts at 70% accuracy, rises more steeply than the stable method, and eventually reaches the same plateau of about 75.5% by 1,000 steps. Both methods converge to the same final accuracy, but the unstable method shows a faster initial growth rate.
- | 训练步数  | 稳定训练精度 (%) | 不稳定训练精度 (%) |
|-------|------------|-------------|
| 0     | 72.0       | 70.0        |
| 200   | 74.0       | 74.0        |
| 400   | 75.0       | 75.0        |
| 600   | 75.5       | 75.5        |
| 800   | 75.5       | 75.5        |
| 1,000 | 75.5       | 75.5        |

## 训练稳定性对比

训练稳定性对比

| 训练步数  | 稳定训练 (精度 %) | 不稳定训练 (精度 %) |
|-------|-------------|--------------|
| 0     | 70.0        | 70.0         |
| 200   | 73.5        | 73.5         |
| 400   | 74.5        | 75.0         |
| 600   | 75.0        | 75.5         |
| 800   | 75.5        | 75.5         |
| 1,000 | 75.5        | 75.5         |

- 
- | 训练步数  | 稳定训练 (精度 %) | 不稳定训练 (精度 %) |
|-------|-------------|--------------|
| 0     | 72.0        | 70.0         |
| 200   | 74.0        | 74.0         |
| 400   | 75.0        | 74.8         |
| 600   | 75.0        | 75.0         |
| 800   | 75.0        | 75.0         |
| 1,000 | 75.0        | 75.0         |

### 训练稳定性对比

训练稳定性对比

| 训练步数  | 稳定训练 (精度 %) | 不稳定训练 (精度 %) |
|-------|-------------|--------------|
| 0     | 70.0        | 70.0         |
| 200   | 73.5        | 73.0         |
| 400   | 74.5        | 74.8         |
| 600   | 75.0        | 75.2         |
| 800   | 75.0        | 75.0         |
| 1,000 | 75.0        | 75.0         |

- 
- A line graph comparing the accuracy of two training methods over 1,000 steps. The y-axis represents accuracy in percentage, ranging from 70 to 74. The x-axis represents training steps, ranging from 0 to 1,000. The '稳定训练' (Stable Training) method, represented by a blue line, starts at approximately 72.0% accuracy at step 0 and increases steadily to about 75.0% by step 1,000. The '不稳定训练' (Unstable Training) method, represented by a red line, starts at 70.0% accuracy at step 0, rises more steeply than the stable method, and eventually reaches the same plateau of approximately 75.0% accuracy by step 1,000.
- | 训练步数  | 稳定训练 (精度 %) | 不稳定训练 (精度 %) |
|-------|-------------|--------------|
| 0     | 72.0        | 70.0         |
| 200   | 73.5        | 73.5         |
| 400   | 74.5        | 74.8         |
| 600   | 74.9        | 75.0         |
| 800   | 75.0        | 75.0         |
| 1,000 | 75.0        | 75.0         |

## 训练稳定性对比

Representation Learning (简单孪生表示学习)

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡

Representation Learning (简单孪生表示学习)  
进一步简化 BYOL 架构

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ▶ ↺ 🔍 ↻



Representation Learning (简单孪生表示学习)  
进一步简化 BYOL 架构  
使用普通编码器和预测头

- Representation Learning (简单孪生表示学习)
- 进一步简化 BYOL 架构
- 使用普通编码器和预测头

Representation Learning (简单孪生表示学习)

- 进一步简化 BYOL 架构
- 使用普通编码器和预测头
- 防止模型塌缩, 无需动量编码器

- **模型全称**: Simple Siamese Representation Learning (简单孪生表示学习)
- **提出背景**: FAIR 于 2021 年提出, 进一步简化 BYOL 架构
- **核心贡献**: 去除动量编码器, 仅使用普通编码器和预测头
- **关键发现**: 停止梯度操作足以防止模型塌缩, 无需动量编码器

Representation Learning (简单孪生表示学习)

- 进一步简化 BYOL 架构
- 使用普通编码器和预测头
- 防止模型塌缩, 无需动量编码器
- 训练稳定


- **模型全称**: Simple Siamese Representation Learning (简单孪生表示学习)
- **提出背景**: FAIR 于 2021 年提出, 进一步简化 BYOL 架构
- **核心贡献**: 去除动量编码器, 仅使用普通编码器和预测头
- **关键发现**: 停止梯度操作足以防止模型塌缩, 无需动量编码器
- **突出特点**: 结构极简, 理论清晰, 训练稳定

- **模型全称**: Simple Siamese Representation Learning (简单孪生表示学习)
- **提出背景**: FAIR 于 2021 年提出, 进一步简化 BYOL 架构
- **核心贡献**: 去除动量编码器, 仅使用普通编码器和预测头
- **关键发现**: 停止梯度操作足以防止模型塌缩, 无需动量编码器
- **突出特点**: 结构极简, 理论清晰, 训练稳定

- **模型全称**: Simple Siamese Representation Learning (简单孪生表示学习)
- **提出背景**: FAIR 于 2021 年提出, 进一步简化 BYOL 架构
- **核心贡献**: 去除动量编码器, 仅使用普通编码器和预测头
- **关键发现**: 停止梯度操作足以防止模型塌缩, 无需动量编码器
- **突出特点**: 结构极简, 理论清晰, 训练稳定


## "大道至简" - 使用最简单的对称结构实现高质量自监督学习

- **网络结构:**



## SimSiam 架构示意图

\_\_\_\_\_




## SimSiam 架构示意图

- **网络结构：**
  - 两个完全相同的编码器分支
  - 共享参数的编码器  $f$

SimSiam 架构示意图



- 两个完全相同的编码器分支
- 共享参数的编码器  $f$
- 预测头  $h$  (仅一侧使用)




## SimSiam 架构示意图




\_\_\_\_\_

- 两个完全相同的编码器分支
- 共享参数的编码器  $f$
- 预测头  $h$  (仅一侧使用)
- 对称结构设计



SimSiam 架构

- 两个完全相同的编码器分支
- 共享参数的编码器  $f$
- 预测头  $h$  (仅一侧使用)
- 对称结构设计




## SimSiam 架构示意图



- 两个完全相同的编码器分支
- 共享参数的编码器  $f$
- 预测头  $h$  (仅一侧使用)
- 对称结构设计

- 移除动量编码器




### SimSiam 架构示意图



- 两个完全相同的编码器分支
- 共享参数的编码器  $f$
- 预测头  $h$  (仅一侧使用)
- 对称结构设计


- 移除动量编码器
- 使用标准的反向传播





- 两个完全相同的编码器分支
- 共享参数的编码器  $f$
- 预测头  $h$  (仅一侧使用)
- 对称结构设计

- 移除动量编码器
- 使用标准的反向传播
- 仅靠停止梯度防止塌缩



### SimSiam 架构示意图


\_\_\_\_\_

- 两个完全相同的编码器分支
- 共享参数的编码器  $f$
- 预测头  $h$  (仅一侧使用)
- 对称结构设计

- 移除动量编码器
- 使用标准的反向传播
- 仅靠停止梯度防止塌缩

$$\mathcal{D}(p_1, z_2) = -\frac{p_1}{\|p_1\|_2} \cdot \frac{z_2}{\|z_2\|_2}$$

$$\mathcal{L} = \frac{1}{2}\mathcal{D}(p_1, \text{stopgrad}(z_2)) + \frac{1}{2}\mathcal{D}(p_2, \text{stopgrad}(z_1))$$



### SimSiam 架构示意图

器后模型不会塌缩?

- **核心问题：**为什么移除动量编码器后模型不会塌缩？

易器后模型不会塌缩？

- **核心问题：**为什么移除动量编码器后模型不会塌缩？
- **数学建模：**



器后模型不会塌缩？

优化 (EM) 算法

- 授课教师：柯嵩宇

器后模型不会塌缩？

最大化 (EM) 算法

- 器后模型不会塌缩？
- 最大化 (EM) 算法

器后模型不会塌缩？

EM 算法

M 步)

- 器后模型不会塌缩？
- 优化 (EM) 算法
- M 步)

器后模型不会塌缩？

优化 (EM) 算法

M 步)

- 将 SimSiam 视为一个期望最大化 (EM) 算法
- 编码器学习特征表示 (E 步)
- 预测头学习特征之间的关系 (M 步)
- 停止梯度操作实现了交替优化

后模型不会塌缩？

化 (EM) 算法

1 步)

$$[\|h_{\theta}(f_{\theta}(\mathcal{T}_1(x))) - \text{sg}(f_{\theta}(\mathcal{T}_2(x)))\|_2^2]$$

- $$\theta_{t+1} = \arg \min_{\theta} \mathbb{E}_{x, \mathcal{T}} [\|h_{\theta}(f_{\theta}(\mathcal{T}_1(x))) - \text{sg}(f_{\theta}(\mathcal{T}_2(x)))\|_2^2]$$

## SimSiam 防止模型塌缩的数学原理

- **核心问题：**为什么移除动量编码器后模型不会塌缩？
- **数学建模：**
  - 将 SimSiam 视为一个期望最大化 (EM) 算法
  - 编码器学习特征表示 (E 步)
  - 预测头学习特征之间的关系 (M 步)
  - 停止梯度操作实现了交替优化

- **优化过程:**

$$\theta_{t+1} = \arg \min_{\theta} \mathbb{E}_{x, \mathcal{T}} [\|h_{\theta}(f_{\theta}(\mathcal{T}_1(x))) - \text{sg}(f_{\theta}(\mathcal{T}_2(x)))\|_2^2]$$

其中  $\text{sg}$  表示停止梯度操作

- ### ● 塌陷解分析:

后模型不会塌缩？

化 (EM) 算法

1 步)

$$[\|h_{\theta}(f_{\theta}(\mathcal{T}_1(x))) - \text{sg}(f_{\theta}(\mathcal{T}_2(x)))\|_2^2]$$

恒等映射

- $$\theta_{t+1} = \arg \min_{\theta} \mathbb{E}_{x, \mathcal{T}} [\|h_{\theta}(f_{\theta}(\mathcal{T}_1(x))) - \text{sg}(f_{\theta}(\mathcal{T}_2(x)))\|_2^2]$$

- **塌陷解分析:**
  - 如果  $f$  是常数函数, 则  $h$  学习恒等映射

器后模型不会塌缩？

化 (EM) 算法

1 步)

$$[[h_{\theta}(f_{\theta}(\mathcal{T}_1(x))) - \text{sg}(f_{\theta}(\mathcal{T}_2(x)))\|_2^2]$$

恒等映射

(MLP)

- $$\theta_{t+1} = \arg \min_{\theta} \mathbb{E}_{x, \mathcal{T}} [\|h_{\theta}(f_{\theta}(\mathcal{T}_1(x))) - \text{sg}(f_{\theta}(\mathcal{T}_2(x)))\|_2^2]$$

- **塌陷解分析:**
  - 如果  $f$  是常数函数, 则  $h$  学习恒等映射
  - 但  $h$  的容量有限 (通常是小的 MLP)



后模型不会塌缩？

化 (EM) 算法

1 步)

$$\|h_{\theta}(f_{\theta}(\mathcal{T}_1(x))) - \text{sg}(f_{\theta}(\mathcal{T}_2(x)))\|_2^2]$$

恒等映射

MLP)

才能让人完成任务

- 将 SimSiam 视为一个期望最大化 (EM) 算法
- 编码器学习特征表示 (E 步)
- 预测头学习特征之间的关系 (M 步)
- 停止梯度操作实现了交替优化

- **优化过程:**

$$\theta_{t+1} = \arg \min_{\theta} \mathbb{E}_{x, \mathcal{T}} [\|h_{\theta}(f_{\theta}(\mathcal{T}_1(x))) - \text{sg}(f_{\theta}(\mathcal{T}_2(x)))\|_2^2]$$

其中  $\text{sg}$  表示停止梯度操作

- **塌陷解分析:**
  - 如果  $f$  是常数函数, 则  $h$  学习恒等映射
  - 但  $h$  的容量有限 (通常是小的 MLP)
  - 这迫使  $f$  必须学习有意义的特征才能让  $h$  完成任务

- **预测头设计:**
  - 3 层 MLP (4096-2048-2048)
  - BatchNorm + ReLU 激活
  - 不使用权重衰减
  - 训练后丢弃, 仅保留编码器

- **训练超参数:**

- 批次大小: 256 或 512
- 优化器: SGD + 余弦退火
- 学习率:  $0.05 \times \text{batch\_size}/256$
- 训练周期: 100-800 epochs

- **对称损失计算：**
  - 对两个增强视图计算交叉损失
  - 总损失 = 平均两个方向的损失
  - 确保两个视图的对称性

- **对称损失计算:**
  - 对两个增强视图计算交叉损失
  - 总损失 = 平均两个方向的损失
  - 确保两个视图的对称性

- **对称损失计算：**
  - 对两个增强视图计算交叉损失
  - 总损失 = 平均两个方向的损失
  - 确保两个视图的对称性
- **停止梯度实现：**
  - PyTorch: `'detach()'` 方法
  - TensorFlow: `'tf.stop_gradient'`
  - 实际实现中非常容易

- **对称损失计算:**
  - 对两个增强视图计算交叉损失
  - 总损失 = 平均两个方向的损失
  - 确保两个视图的对称性
- **停止梯度实现:**
  - PyTorch: `'detach()'` 方法
  - TensorFlow: `'tf.stop_gradient'`
  - 实际实现中非常容易

- **对称损失计算：**
  - 对两个增强视图计算交叉损失
  - 总损失 = 平均两个方向的损失
  - 确保两个视图的对称性
- **停止梯度实现：**
  - PyTorch: `'detach()'` 方法
  - TensorFlow: `'tf.stop_gradient'`
  - 实际实现中非常容易

- 3 层 MLP (4096-2048-2048)
- BatchNorm + ReLU 激活
- 不使用权重衰减
- 训练后丢弃，仅保留编码器

- 批次大小: 256 或 512
- 优化器: SGD + 余弦退火
- 学习率:  $0.05 \times \text{batch\_size}/256$
- 训练周期: 100-800 epochs

- 对两个增强视图计算交叉损失
- 总损失 = 平均两个方向的损失
- 确保两个视图的对称性

- PyTorch: `'detach()'` 方法
- TensorFlow: `'tf.stop_gradient'`
- 实际实现中非常容易

- **预测头对于防止塌缩至关重要 (移除后精度下降 14%)**

A large, faint, circular watermark of the Fuzhou University logo is centered on the page. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top arc and in Chinese, "福州大学", around the bottom arc. The year "1958" is positioned at the bottom center of the circle. In the middle of the logo is a large, stylized Chinese character "福" (Fú), which is a common symbol for good fortune. The entire watermark is rendered in a light gray or off-white color, serving as a background element.

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡

A large, faint, circular watermark of the Fuzhou University logo is centered on the slide. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top arc and in Chinese, "福州大学", around the bottom arc, with the year "1958" at the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú). A small red square icon is located in the top-left corner of the slide. At the bottom center, there is a navigation bar with several small, light-blue icons for presentation control.

- **理论贡献:**
  - 证明动量编码器不是自监督学习的必需品



- **理论贡献:**
  - 证明动量编码器不是自监督学习的必需品
  - 提供了一种防止塌缩的新视角 (停止梯度)

- 证明动量编码器不是自监督学习的必需品
- 提供了一种防止塌缩的新视角 (停止梯度)
- 启发了更简单的自监督学习架构

- 证明动量编码器不是自监督学习的必需品
- 提供了一种防止塌缩的新视角 (停止梯度)
- 启发了更简单的自监督学习架构

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ▶ ↺ 🔍 ↻

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ↺ 🔍 ↻

- **实际优势：**

- 代码实现极简（核心代码不到100行）
- 训练过程无需特殊技巧

- **实际优势：**

- 代码实现极简（核心代码不到100行）
- 训练过程无需特殊技巧
- 适合资源受限的环境

- **局限性：**

- **局限性:**

- 代码实现极简（核心代码不到100行）
- 训练过程无需特殊技巧
- 适合资源受限的环境

- **实际优势：**

- 代码实现极简（核心代码不到100行）
- 训练过程无需特殊技巧
- 适合资源受限的环境

- **局限性：**
  - 绝对精度仍有提升空间

- **实际优势：**

- **局限性:**

- 绝对精度仍有提升空间



- **局限性：**
  - 绝对精度仍有提升空间
  - 对预测头设计敏感

- **实际优势：**

- **局限性:**

- A set of small navigation icons typically found in Beamer presentations, including symbols for back, forward, search, and other slide controls.

- **局限性：**
  - 绝对精度仍有提升空间
  - 对预测头设计敏感
  - 需要对称损失计算

- **实际优势：**

- **局限性:**

- 绝对精度仍有提升空间
- 对预测头设计敏感
- 需要对称损失计算

- **局限性：**
  - 绝对精度仍有提升空间
  - 对预测头设计敏感
  - 需要对称损失计算
- **后续发展：**

- **实际优势：**

- **局限性:**

- 绝对精度仍有提升空间
- 对预测头设计敏感
- 需要对称损失计算

- **后续发展:**

- **局限性：**
  - 绝对精度仍有提升空间
  - 对预测头设计敏感
  - 需要对称损失计算
- **后续发展：**
  - DINO（无监督学习的进一步简化）

- **局限性：**
  - 绝对精度仍有提升空间
  - 对预测头设计敏感
  - 需要对称损失计算
- **后续发展：**
  - DINO（无监督学习的进一步简化）

- **局限性：**
  - 绝对精度仍有提升空间
  - 对预测头设计敏感
  - 需要对称损失计算
- **后续发展：**
  - DINO（无监督学习的进一步简化）
  - Barlow Twins（基于相关性的方法）

- **局限性：**
  - 绝对精度仍有提升空间
  - 对预测头设计敏感
  - 需要对称损失计算
- **后续发展：**
  - DINO（无监督学习的进一步简化）
  - Barlow Twins（基于相关性的方法）

- **局限性：**
  - 绝对精度仍有提升空间
  - 对预测头设计敏感
  - 需要对称损失计算
- **后续发展：**
  - DINO（无监督学习的进一步简化）
  - Barlow Twins（基于相关性的方法）
  - VICReg（基于方差的简化方法）

- **局限性：**
  - 绝对精度仍有提升空间
  - 对预测头设计敏感
  - 需要对称损失计算
- **后续发展：**
  - DINO（无监督学习的进一步简化）
  - Barlow Twins（基于相关性的方法）
  - VICReg（基于方差的简化方法）

## SimSiam 的启发

- **简化胜于复杂**: 在保证性能的前提下, 尽量简化架构
- **原理探索**: 理解为什么简单方法也能有效工作
- **实用导向**: 优先考虑实现成本和部署难度

## 核心思想

- **核心目标：**学习高质量的特征表示，使得相似样本在特征空间中靠近，不相似样本远离



## 核心思想

- **核心目标**: 学习高质量的特征表示, 使得相似样本在特征空间中靠近, 不相似样本远离
- **关键组件**: 数据增强、编码器、对比损失、温度参数

## 核心思想

- **核心目标**: 学习高质量的特征表示, 使得相似样本在特征空间中靠近, 不相似样本远离
- **关键组件**: 数据增强、编码器、对比损失、温度参数
- **核心挑战**: 模型塌缩——如何避免所有样本映射到同一点

## 关键技术演进

## ViT 时代

- SimCLR: 大批次+强数据增强

## 关键技术演进

## ViT 时代

- SimCLR: 大批次+强数据增强
- MoCo 系列: 动量编码器+队列

## 关键技术演进

## ViT 时代

- SimCLR: 大批次+强数据增强
- MoCo 系列: 动量编码器+队列
- 需要大量负样本

## 关键技术演进

## 无负样本方法

## ViT 时代

- SimCLR: 大批次+强数据增强
- MoCo 系列: 动量编码器+队列
- 需要大量负样本

- BYOL: 在线/目标网络+动量更新



## 关键技术演进

## ViT 时代

- BYOL: 在线/目标网络+动量更新
- SimSiam: 停止梯度+对称损失

## 关键技术演进

## ViT 时代

- BYOL: 在线/目标网络+动量更新
- SimSiam: 停止梯度+对称损失
- 简化训练复杂度



## 关键技术演进

## 无负样本方法

## ViT 时代

- MoCo v3: 适配 Vision Transformer

## 关键技术演进

## 无负样本方法

## ViT 时代

- MoCo v3: 适配 Vision Transformer
- DINO、MAE 等新方法

## 对比学习的发展历程

## 关键技术演进

## 经典对比学习

- SimCLR: 大批次+强数据增强
- MoCo 系列: 动量编码器+队列
- 需要大量负样本

## 无负样本方法

- BYOL: 在线/目标网络+动量更新
- SimSiam: 停止梯度+对称损失
- 简化训练复杂度

## ViT 时代

- MoCo v3: 适配 Vision Transformer
- DINO、MAE 等新方法
- 关注训练稳定性

## 对比学习

## 对比学习在时空数据上的应用

## 生成式方法

## ② 时空自动机器学习

A large, faint watermark of the Fuzhou University logo is centered on the page. The logo is circular, featuring the university's name in English, "FUZHOU UNIVERSITY", around the top and the Chinese characters "福州大学" around the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú), which means "blessing" or "good fortune". Below the character "福" is the year "1958". At the very bottom of the page, there is a small navigation bar with several icons: a square, a circle, a triangle, and a set of three horizontal lines, likely representing different views or functions of the presentation software.

- 复杂的时空依赖关系
- 显著的异质性 (时间/空间)
- 数据稀疏性和不平衡性
- 动态演化的时空模式

- 复杂的时空依赖关系
- 显著的异质性 (时间/空间)
- 数据稀疏性和不平衡性
- 动态演化的时空模式

A large, faint watermark of the Fuzhou University logo is centered on the page. The logo is circular, featuring the university's name in English, "FUZHOU UNIVERSITY", around the top and the Chinese characters "福州大学" around the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú), which means "blessing" or "good fortune". Below the character "福" is the year "1958". At the very bottom of the page, there is a small navigation bar with several icons: a square, a circle, a triangle, and a series of arrows.

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ◀ ↺ 🔍 ↻

- **对比学习的优势：**
  - 利用大量无标注数据
  - 学习鲁棒的时空表示
  - 处理时空异质性
  - 提升模型泛化能力

- **对比学习的优势：**
  - 利用大量无标注数据
  - 学习鲁棒的时空表示
  - 处理时空异质性
  - 提升模型泛化能力

- **对比学习的优势：**
  - 利用大量无标注数据
  - 学习鲁棒的时空表示
  - 处理时空异质性
  - 提升模型泛化能力
- **应用场景：**
  - 交通流量预测
  - 犯罪热点预测
  - 空气质量预测
  - 城市人群流动分析

- **对比学习的优势：**
  - 利用大量无标注数据
  - 学习鲁棒的时空表示
  - 处理时空异质性
  - 提升模型泛化能力
- **应用场景：**
  - 交通流量预测
  - 犯罪热点预测
  - 空气质量预测
  - 城市人群流动分析



“不相似”的样本对？

◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ↺ 🔍 ↻

“不相似” 的样本对？

- 空间邻近 + 时间相近 → 正样本

“不相似” 的样本对？

大样本

样本

- 空间邻近 + 时间相近 → 正样本
- 空间遥远 或 时间差异大 → 负样本

- 空间邻近 + 时间相近 → 正样本
- 空间遥远 或 时间差异大 → 负样本

\_\_\_\_\_

- **核心贡献：**首次将对比学习系统引入时空图



STCCL 双公共加构三音图

- **核心贡献：**首次将对比学习系统引入时空图预测
- **双分支架构：**

```

graph TD
 A([时空图数据]) --> B[时间偏移]
 A --> C[空间掩码]
 A --> D[时空图编码器]
 D --> E[预测分支]
 D --> F[对比分支]
 E --> G([预测结果])
 F --> H([对比损失])

```

STGCL 双分支架构示意图

- 
- ```
graph TD; A([时空图数据]) --> B[时间偏移]; A --> C[空间掩码]; A --> D[时空图编码器]; B --> D; C --> D; D --> E[预测分支]; D --> F[对比分支]; E --> G([预测结果]); F --> H([对比损失]);
```

STGCL 双分支架构示意图

- **核心贡献：**首次将对比学习系统引入时空图预测
 - **双分支架构：**
 - **预测分支：**直接输出预测结果
-
- ```

graph TD
 A([时空图数据]) --> B[时间偏移]
 A --> C[空间掩码]

```



STGCL 双分支架构示意图

- 
 文部科学省
 


 厚生労働省
 


 文部科学省
 


 厚生労働省


- **核心贡献：**首次将对比学习系统引入时空图预测
- **双分支架构：**
  - 预测分支：直接输出预测结果
  - 对比分支：通过对比损失学习特征
  - **共享编码器，联合优化**

```

graph TD
 A([时空图数据]) --> B[时间偏移]
 A --> C[空间掩码]
 A --> D[时空图编码器]
 D --> E[预测分支]
 D --> F[对比分支]
 E --> G([预测结果])
 F --> H([对比损失])

```

STGCL 双分支架构示意图





- **核心贡献：**首次将对比学习系统引入时空图预测
- **双分支架构：**
  - 预测分支：直接输出预测结果
  - 对比分支：通过对比损失学习特征
  - 共享编码器，联合优化
- **多尺度对比学习：**




STGCL 双分支架构示意图

```

graph TD
 A([时空图数据]) --> B[时间偏移]
 A --> C[空间掩码]
 A --> D[时空图编码器]
 B --> D
 C --> D
 D --> E[预测分支]
 D --> F[对比分支]
 E --> G([预测结果])
 F --> H([对比损失])

```



\_\_\_\_\_

- 
- ```
graph TD; A([时空图数据]) --> B[时间偏移]; A --> C[空间掩码]; A --> D[时空图编码器]; B --> D; C --> D; D --> E[预测分支]; D --> F[对比分支]; E --> G([预测结果]); F --> H([对比损失]);
```
- 时空图数据
- 时间偏移
- 空间掩码
- 时空图编码器
- 预测分支
- 对比分支
- 预测结果
- 对比损失

-
- ```

graph TD
 A([时空图数据]) --> B[时间偏移]
 A --> C[空间掩码]
 A --> D[时空图编码器]
 B --> D
 C --> D
 D --> E[预测分支]
 D --> F[对比分支]
 E --> G([预测结果])
 F --> H([对比损失])

```

\_\_\_\_\_

- 
- ```
graph TD; A([时空图数据]) --> B[时间偏移]; A --> C[空间掩码]; A --> D[时空图编码器]; B --> D; C --> D; D --> E[预测分支]; D --> F[对比分支]; E --> G([预测结果]); F --> H([对比损失]);
```

-
- ```
graph TD; A([时空图数据]) --> B[时间偏移]; A --> C[空间掩码]; A --> D[时空图编码器]; B --> D; C --> D; D --> E[预测分支]; D --> F[对比分支]; E --> G([预测结果]); F --> H([对比损失]);
```

- **时空图增强策略:**



A large, faint, circular watermark of the Fuzhou University logo is centered on the page. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top arc and in Chinese, "福州大学", around the bottom arc, with the founding year "1958" at the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú).

- A set of small navigation icons typically found in Beamer presentations, including symbols for back, forward, search, and other slide controls.



A large, faint watermark of the Fuzhou University logo is centered on the slide. The logo is circular, featuring the text "FUZHOU UNIVERSITY" around the top and "福州大学" around the bottom. In the center is a large Chinese character "福" (Fú) and the year "1958".

- A set of small navigation icons typically found in Beamer presentations, including symbols for back, forward, search, and other slide controls.





边  
证

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ◀ ↺ 🔍 ↻

边  
证

A large, faint, circular watermark of the Fuzhou University logo is centered in the background. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top arc and in Chinese, "福州大学", around the bottom arc, with the year "1958" at the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú), which means "blessing" or "good fortune".

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ↺ 🔍 ↻

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ↺ 🔍 ↻



- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ↺ 🔍 ↻



- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ↺ 🔍 ↻

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ↺ 🔍 ↻



- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ↺ 🔍 ↻

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ↺ 🔍 ↻

- 性能表现：

- **性能表现:**

- **性能表现：**
  - 城郊区域预测误差降低 23%

- A set of small navigation icons typically found in Beamer presentations, including symbols for back, forward, search, and other slide controls.

- **性能表现：**
  - 城郊区域预测误差降低 23%
  - 高峰时段预测精度提升 15%

- **性能表现:**

- 城郊区域预测误差降低 23%
- 高峰时段预测精度提升 15%

- 同一节点不同时间 → 正样本
- 不同节点同一时间 → 负样本
- 跨时空对比：混合时空差异

- 渐进式增强：从易到难
- 温度参数调整
- 负样本挖掘策略

- **性能表现：**
  - 城郊区域预测误差降低 23%
  - 高峰时段预测精度提升 15%
  - **稀疏数据区域效果显著**

- **性能表现:**

- 城郊区域预测误差降低 23%
- 高峰时段预测精度提升 15%
- 稀疏数据区域效果显著

- 同一节点不同时间 → 正样本
- 不同节点同一时间 → 负样本
- 跨时空对比：混合时空差异

- 渐进式增强：从易到难
- 温度参数调整
- 负样本挖掘策略

- **性能表现：**
  - 城郊区域预测误差降低 23%
  - 高峰时段预测精度提升 15%
  - 稀疏数据区域效果显著
- **消融实验发现：**

- **性能表现:**
  - 城郊区域预测误差降低 23%
  - 高峰时段预测精度提升 15%
  - 稀疏数据区域效果显著
- **消融实验发现:**

- **性能表现：**
  - 城郊区域预测误差降低 23%
  - 高峰时段预测精度提升 15%
  - 稀疏数据区域效果显著
- **消融实验发现：**
  - 多尺度对比最重要 (+8%)

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ≡ ≡ ↺ 🔍 ↻




- **性能表现：**
  - 城郊区域预测误差降低 23%
  - 高峰时段预测精度提升 15%
  - 稀疏数据区域效果显著
- **消融实验发现：**
  - 多尺度对比最重要 (+8%)
  - 时间增强比空间增强更重要

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ↺ 🔍 ↻

- **性能表现：**
  - 城郊区域预测误差降低 23%
  - 高峰时段预测精度提升 15%
  - 稀疏数据区域效果显著
- **消融实验发现：**
  - 多尺度对比最重要 (+8%)
  - 时间增强比空间增强更重要
  - 联合训练优于交替训练

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ↺ 🔍 ↻

- **核心创新：**自适应处理时空异质性



## ST-SSL 多任务学习框架

\_\_\_\_\_

- מנהל מחלקת המבחנים



|     |        |        |
|-----|--------|--------|
| 主任务 | 辅助任务 1 | 辅助任务 2 |
|-----|--------|--------|

\_\_\_\_\_

- 多任务融合损失



```

graph TD
 A([时空数据]) --> B[动态编码器]
 B --> C[主任务
未来预测]
 B --> D[辅助任务 1
空间异质性]
 B --> E[辅助任务 2
时间异质性]
 C --> F([预测损失])
 D --> G([对比损失])
 E --> H([重建损失])
 F --> I[多任务融合损失]
 G --> I
 H --> I

```

ST-SSL 多任务学习框架

- 
- ```
graph TD; A([时空数据]) --> B[动态编码器]; B --> C[主任务  
未来预测]; B --> D[辅助任务 1  
空间异质性]; B --> E[辅助任务 2  
时间异质性]; C --> F([预测损失]); D --> G([对比损失]); E --> H([重建损失]); F --> I[多任务融合损失]; G --> I; H --> I;
```

ST-SSL 多任务学习框架

A large, faint, circular watermark of the Fuzhou University logo is centered on the slide. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top arc and in Chinese, "福州大学", around the bottom arc, with the founding year "1958" at the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú).

- 空间异质性: 不同区域模式不同
- 时间异质性: 不同时段模式不同
- 交叉异质性: 时空交互效应

- 空间异质性: 不同区域模式不同
- 时间异质性: 不同时段模式不同
- 交叉异质性: 时空交互效应

A large, faint, circular watermark of the Fuzhou University logo is centered on the page. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top arc and in Chinese, "福州大学", around the bottom arc, with the year "1958" at the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú).

- **时空异质性建模:**
 - 空间异质性: 不同区域模式不同
 - 时间异质性: 不同时段模式不同
 - 交叉异质性: 时空交互效应
- **自适应机制:**
 - 基于数据分布调整增强强度
 - 异质性强的区域 → 强增强
 - 异质性弱的区域 → 弱增强

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ↺ 🔍 ↻

- **可视化验证：**
 - t-SNE 可视化特征空间
 - 不同区域形成明显聚类
 - 时空模式被有效编码

- **可视化验证:**
 - t-SNE 可视化特征空间
 - 不同区域形成明显聚类
 - 时空模式被有效编码

- **可视化验证：**
 - t-SNE 可视化特征空间
 - 不同区域形成明显聚类
 - 时空模式被有效编码
- **对比分析：**
 - 优于传统监督学习方法
 - 在稀疏数据上优势明显
 - 训练稳定性更好

- **可视化验证：**
 - t-SNE 可视化特征空间
 - 不同区域形成明显聚类
 - 时空模式被有效编码
- **对比分析：**
 - 优于传统监督学习方法
 - 在稀疏数据上优势明显
 - 训练稳定性更好

- **AutoST (2023): 犯罪预测**
 - 自适应时空图构建
 - 多层次对比学习
 - 性能提升: MAE↓12%, F1↑8%
 - 优于传统图神经网络方法

A large, faint, circular watermark of the Fuzhou University logo is centered on the page. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top arc and in Chinese, "福州大学", around the bottom arc. The year "1958" is positioned at the bottom center of the circle. In the middle of the logo is a large, stylized Chinese character "福" (Fú), which is part of the university's emblem.

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ◀ ↺ 🔍 ↻

- **AutoST (2023): 犯罪预测**
 - 自适应时空图构建
 - 多层次对比学习
 - 性能提升: MAE↓12%, F1↑8%
 - 优于传统图神经网络方法
- **TempGCL: 温度预测**
 - 气象站数据时空关联
 - 跨区域对比学习
 - 极端天气事件预测
 - 预测精度提升 15%
- **PolluCL: 空气质量预测**
 - 多污染物联合建模
 - 时空传播模式学习
 - 实时空气质量预警

- **TrajCL: 轨迹数据挖掘**
 - 移动轨迹模式识别
 - 异常轨迹检测
 - 人群流动预测
 - 应用：疫情防控、城市规划

- **TrajCL: 轨迹数据挖掘**
 - 移动轨迹模式识别
 - 异常轨迹检测
 - 人群流动预测
 - 应用：疫情防控、城市规划

- **TrajCL: 轨迹数据挖掘**
 - 移动轨迹模式识别
 - 异常轨迹检测
 - 人群流动预测
 - 应用: 疫情防控、城市规划
- **UrbanCL: 城市计算**
 - 多源数据融合
 - 城市功能区识别
 - 土地利用分析
 - 城市发展模式挖掘

- **TrajCL: 轨迹数据挖掘**
 - 移动轨迹模式识别
 - 异常轨迹检测
 - 人群流动预测
 - 应用：疫情防控、城市规划
- **UrbanCL: 城市计算**
 - 多源数据融合
 - 城市功能区识别
 - 土地利用分析
 - 城市发展模式挖掘

核心技术创新

① 时空增强策略：针对时空特性的数据增强方法

核心技术创新

- ① **时空增强策略**: 针对时空特性的数据增强方法
- ② **正负样本定义**: 基于时空邻近性的样本对构建

核心技术创新

- ① **时空增强策略**: 针对时空特性的数据增强方法
- ② **正负样本定义**: 基于时空邻近性的样本对构建
- ③ **多尺度对比**: 节点级、图级、区域级多层次学习

核心技术创新

- ① **时空增强策略**: 针对时空特性的数据增强方法
- ② **正负样本定义**: 基于时空邻近性的样本对构建
- ③ **多尺度对比**: 节点级、图级、区域级多层次学习
- ④ **异质性建模**: 自适应处理时空分布差异

核心技术创新

- ① **时空增强策略**: 针对时空特性的数据增强方法
- ② **正负样本定义**: 基于时空邻近性的样本对构建
- ③ **多尺度对比**: 节点级、图级、区域级多层次学习
- ④ **异质性建模**: 自适应处理时空分布差异
- ⑤ **多任务学习**: 联合优化预测与表示学习

实际应用价值

- **城市治理：交通管理、公共安全**

实际应用价值

- **城市治理**： 交通管理、 公共安全
- **环境监测**： 空气质量、 气象预测

时空对比学习的意义

对比学习为时空数据挖掘提供了新的范式，通过自监督学习从海量无标注数据中学习有意义的时空表示，在智慧城市、环境监测、公共安全等领域展现出巨大应用潜力。

实际应用价值

- **城市治理**: 交通管理、公共安全
- **环境监测**: 空气质量、气象预测
- **商业应用**: 选址分析、需求预测

对比学习为时空数据挖掘提供了新的范式，通过自监督学习从海量无标注数据中学习有意义的时空表示，在智慧城市、环境监测、公共安全等领域展现出巨大应用潜力。

实际应用价值

- **城市治理**： 交通管理、 公共安全
- **环境监测**： 空气质量、 气象预测
- **商业应用**： 选址分析、 需求预测
- **社会服务**： 应急响应、 资源配置

时空对比学习的意义

对比学习为时空数据挖掘提供了新的范式，通过自监督学习从海量无标注数据中学习有意义的时空表示，在智慧城市、环境监测、公共安全等领域展现出巨大应用潜力。

实际应用价值

- **城市治理**：交通管理、公共安全
 - **环境监测**：空气质量、气象预测
 - **商业应用**：选址分析、需求预测
 - **社会服务**：应急响应、资源配置
- **性能提升**：预测精度显著提高

时空对比学习的意义

对比学习为时空数据挖掘提供了新的范式，通过自监督学习从海量无标注数据中学习有意义的时空表示，在智慧城市、环境监测、公共安全等领域展现出巨大应用潜力。

实际应用价值

- **城市治理**: 交通管理、公共安全
 - **环境监测**: 空气质量、气象预测
 - **商业应用**: 选址分析、需求预测
 - **社会服务**: 应急响应、资源配置
- **性能提升**: 预测精度显著提高
 - **数据效率**: 减少对标注数据的依赖

对比学习为时空数据挖掘提供了新的范式，通过自监督学习从海量无标注数据中学习有意义的时空表示，在智慧城市、环境监测、公共安全等领域展现出巨大应用潜力。

实际应用价值

- **城市治理**: 交通管理、公共安全
 - **环境监测**: 空气质量、气象预测
 - **商业应用**: 选址分析、需求预测
 - **社会服务**: 应急响应、资源配置
 - **性能提升**: 预测精度显著提高
 - **数据效率**: 减少对标注数据的依赖
 - **泛化能力**: 适应不同城市和场景

时空对比学习的意义

对比学习为时空数据挖掘提供了新的范式，通过自监督学习从海量无标注数据中学习有意义的时空表示，在智慧城市、环境监测、公共安全等领域展现出巨大应用潜力。

实际应用价值

- **城市治理**: 交通管理、公共安全
 - **环境监测**: 空气质量、气象预测
 - **商业应用**: 选址分析、需求预测
 - **社会服务**: 应急响应、资源配置
 - **性能提升**: 预测精度显著提高
 - **数据效率**: 减少对标注数据的依赖
 - **泛化能力**: 适应不同城市和场景
 - **鲁棒性**: 处理数据稀疏和不平衡


对比学习为时空数据挖掘提供了新的范式，通过自监督学习从海量无标注数据中学习有意义的时空表示，在智慧城市、环境监测、公共安全等领域展现出巨大应用潜力。

掩码模型

② 时空自动机器学习

GAN 基础：从博弈到生成

- **核心思想：警察与小偷的博弈**
 - 生成器（小偷）：伪造假币
 - 判别器（警察）：识别假币
 - 对抗训练：小偷越来越真，警察越来越强



生成对抗网络 (GAN) 架构示意图

- **类比理解：**
 - 生成器 → 造假者
 - 判别器 → 鉴伪专家
 - 对抗训练 → 互相学习进步
 - 最终目标 → 生成逼真的“假货”



符号定义

- G : 生成器 (Generator)



符号定义

- G : 生成器 (Generator)
- D : 判别器 (Discriminator)

符号定义

- G : 生成器 (Generator)
- D : 判别器 (Discriminator)
- z : 随机噪声, $z \sim p_z(z)$

符号定义

- G : 生成器 (Generator)
- D : 判别器 (Discriminator)
- z : 随机噪声, $z \sim p_z(z)$
- x : 真实数据, $x \sim p_{data}(x)$

符号定义

- G : 生成器 (Generator)
- D : 判别器 (Discriminator)
- z : 随机噪声, $z \sim p_z(z)$
- x : 真实数据, $x \sim p_{data}(x)$
- $G(z)$: 生成器生成的假数据



符号定义

- G : 生成器 (Generator)
- D : 判别器 (Discriminator)
- z : 随机噪声, $z \sim p_z(z)$
- x : 真实数据, $x \sim p_{data}(x)$
- $G(z)$: 生成器生成的假数据

目标函数

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{data}} [\log D(x)] + \mathbb{E}_{z \sim p_z} [\log(1 - D(G(z)))]$$

符号定义

- G : 生成器 (Generator)
- D : 判别器 (Discriminator)
- z : 随机噪声, $z \sim p_z(z)$
- x : 真实数据, $x \sim p_{data}(x)$
- $G(z)$: 生成器生成的假数据

直观理解

- 判别器 D : 最大化识别准确率
- 生成器 G : 最小化被识别率
- 零和博弈: D 的收益是 G 的损失

目标函数

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{data}} [\log D(x)] + \mathbb{E}_{z \sim p_z} [\log(1 - D(G(z)))]$$

$$D(G(z^{(i)})) + \log(1 - D(G(z^{(i)})))];$$

8 更新 G : $\nabla_{\theta_g} \frac{1}{m} \sum_{i=1}^m \log(1 - D(G(z^{(i)})))$;

原始 GAN 的问题

- **训练不稳定**
 - 生成器和判别器不平衡
 - 容易发散
 - 需要仔细的超参数调节

模式崩塌例子

- 生成数字"1" 效果很好
- 但永远不生成"2"、"3" 等
- 判别器被骗过了
- 生成多样性严重不足

原始 GAN 的问题

- **训练不稳定**
 - 生成器和判别器不平衡
 - 容易发散
 - 需要仔细的超参数调节
- **模式崩塌**
 - 生成器只学会生成几种样本
 - 多样性不足
 - 生成器“偷懒”，只记住部分模式

模式崩塌例子

- 生成数字"1" 效果很好
- 但永远不生成"2"、"3" 等
- 判别器被骗过了
- 生成多样性严重不足

原始 GAN 的问题

- **训练不稳定**
 - 生成器和判别器不平衡
 - 容易发散
 - 需要仔细的超参数调节
- **模式崩塌**
 - 生成器只学会生成几种样本
 - 多样性不足
 - 生成器“偷懒”，只记住部分模式

模式崩塌例子

- 生成数字"1" 效果很好
- 但永远不生成"2"、"3" 等
- 判别器被骗过了
- 生成多样性严重不足

改进方法

原始 GAN 的问题

- **训练不稳定**
 - 生成器和判别器不平衡
 - 容易发散
 - 需要仔细的超参数调节
- **模式崩塌**
 - 生成器只学会生成几种样本
 - 多样性不足
 - 生成器“偷懒”，只记住部分模式

改进方法

- **WGAN**: 用 Wasserstein 距离
 - 解决训练不稳定
 - 提供有意义的训练信号

原始 GAN 的问题

- **训练不稳定**
 - 生成器和判别器不平衡
 - 容易发散
 - 需要仔细的超参数调节
- **模式崩塌**
 - 生成器只学会生成几种样本
 - 多样性不足
 - 生成器“偷懒”，只记住部分模式

改进方法

- **WGAN**: 用 Wasserstein 距离
- **CGAN**: 条件生成
 - 控制生成内容
 - 提高生成多样性

GAN 的训练问题与改进

原始 GAN 的问题

- **训练不稳定**
 - 生成器和判别器不平衡
 - 容易发散
 - 需要仔细的超参数调节
- **模式崩塌**
 - 生成器只学会生成几种样本
 - 多样性不足
 - 生成器“偷懒”，只记住部分模式

改进方法

- **WGAN**: 用 Wasserstein 距离
- **CGAN**: 条件生成
- **渐进式训练**
 - 从低分辨率开始
 - 逐步增加分辨率

原始 GAN 的问题


- **训练不稳定**
 - 生成器和判别器不平衡
 - 容易发散
 - 需要仔细的超参数调节
- **模式崩塌**
 - 生成器只学会生成几种样本
 - 多样性不足
 - 生成器“偷懒”，只记住部分模式

改进方法

- **WGAN**: 用 Wasserstein 距离
- **CGAN**: 条件生成
- **渐进式训练**
- **谱归一化**
 - 稳定判别器训练
 - 防止梯度爆炸

核心思想

- 传统 GAN: 随机生成
- cGAN: 基于条件 y 生成
- 示例: 给定标签“猫” → 生成猫的图片




cGAN 结构示意图

核心思想

- 传统 GAN: 随机生成
- cGAN: 基于条件 y 生成
- 示例: 给定标签“猫” → 生成猫的图片

直观理解

- 判别器任务: 判断“图片 x 与条件 y 是否匹配”
- 生成器任务: 生成“与条件 y 匹配的逼真图片”



cGAN 结构示意图

A large, faint watermark of Fuzhou University's logo is centered on the page. The logo is circular, with the English text "FUZHOU UNIVERSITY" around the top and "福州大学" (Fuzhou University) in Chinese around the bottom. In the center of the logo is a large white character "福" (Fú), which is a stylized representation of the university's name. The background of the slide is a solid light blue.

核心思想

- 传统 GAN: 随机生成
- cGAN: 基于条件 y 生成
- 示例: 给定标签“猫” $\rightarrow$ 生成猫的图片

直观理解

- 判别器任务：判断“图片 x 与条件 y 是否匹配”
- 生成器任务：生成“与条件 y 匹配的逼真图片”

cGAN 的应用场景

cGAN 的应用场景

- 判别器任务: 判断“图片 x 与条件 y 是否匹配”
- 生成器任务: 生成“与条件 y 匹配的逼真图片”

直观理解

核心思想

- 传统 GAN: 随机生成
- cGAN: 基于条件 y 生成
- 示例: 给定标签“猫” → 生成猫的图片

直观理解

- 判别器任务: 判断" 图片 x 与条件 y 是否匹配"
- 生成器任务: 生成" 与条件 y 匹配的逼真图片"

cGAN 的应用场景

- **图像到图像转换**
 - 语义分割图 → 真实图片
 - 白天 → 夜晚
 - 草图 → 上色图


- 判别器任务: 判断“图片 x 与条件 y 是否匹配”
- 生成器任务: 生成“与条件 y 匹配的逼真图片”

- **图像到图像转换**
- **文本到图像生成**
 - 文字描述 → 对应图片
 - 属性编辑：微笑、年龄等

- 判别器任务: 判断“图片 x 与条件 y 是否匹配”
- 生成器任务: 生成“与条件 y 匹配的逼真图片”

- **图像到图像转换**
- **文本到图像生成**
- **风格迁移**
 - 普通照片 → 艺术风格
 - 季节变换

- JS 散度导致梯度消失
- 训练信号不连续
- 模式崩塌严重



JS 散度 vs Wasserstein 距离

- **原始 GAN 的问题:**
 - JS 散度导致梯度消失
 - 训练信号不连续
 - 模式崩塌严重
- **Wasserstein 距离:**
 - 地球移动距离 (Earth Mover's Distance)
 - 衡量两个分布的"距离"
 - 即使没有重叠也有梯度

JS 散度

无重叠时
梯度为 0

Wasserstein 距离

仍有梯度
可优化

JS 散度 vs Wasserstein 距离

-
- JS 散度
- P Q
- 无重叠时
梯度为 0
- Wasserstein 距离
- P Q
- 仍有梯度
可优化

JS 散度 vs Wasserstein 距离

- **原始 GAN 的问题:**
 - JS 散度导致梯度消失
 - 训练信号不连续
 - 模式崩塌严重
- **Wasserstein 距离:**
 - 地球移动距离 (Earth Mover's Distance)
 - 衡量两个分布的"距离"
 - 即使没有重叠也有梯度
- **核心改进:**
 - 用 Wasserstein 距离替代 JS 散度
 - 判别器改为 Lipschitz 连续函数
 - 权重裁剪或谱归一化

JS 散度

无重叠时
梯度为 0

Wasserstein 距离

仍有梯度
可优化

JS 散度 vs Wasserstein 距离

- 授课教师：柯嵩宇

- **原始 GAN 的问题:**
 - JS 散度导致梯度消失
 - 训练信号不连续
 - 模式崩塌严重
- **Wasserstein 距离:**
 - 地球移动距离 (Earth Mover's Distance)
 - 衡量两个分布的"距离"
 - 即使没有重叠也有梯度
- **核心改进:**
 - 用 Wasserstein 距离替代 JS 散度
 - 判别器改为 Lipschitz 连续函数
 - 权重裁剪或谱归一化

The diagram illustrates the difference between JS Divergence and Wasserstein Distance. In the top section, two non-overlapping distributions, P (blue oval) and Q (red oval), are shown. The text 'JS 散度' (JS Divergence) is above them, and '无重叠时 梯度为 0' (When there is no overlap, the gradient is 0) is written between them. In the bottom section, the same two distributions are shown, but a dashed arrow points from P to Q , labeled 'Wasserstein 距离' (Wasserstein Distance). Below this, it says '仍有梯度 可优化' (There is still a gradient, can be optimized). The overall title for the diagram is 'JS 散度 vs Wasserstein 距离'.

-
- JS 散度
- 无重叠时
梯度为 0
- Wasserstein 距离
- 仍有梯度
可优化

JS 散度 vs Wasserstein 距离

WGAN 的关键技术

- Lipschitz 约束
- 权重裁剪 (Weight Clipping)
 - 限制权重在 $[-c, c]$ 内
 - 简单但可能影响表达能力

- ## WGAN 的关键技术

- **Lipschitz 约束**
- **权重裁剪 (Weight Clipping)**
 - 限制权重在 $[-c, c]$ 内
 - 简单但可能影响表达能力

WGAN 的关键技术

- **Lipschitz 约束**
- **权重裁剪 (Weight Clipping)**
- **梯度惩罚 (Gradient Penalty)**
 - 在损失中加梯度惩罚项
 - 更稳定的 Lipschitz 约束

- ## WGAN 的关键技术

- Lipschitz 约束
- 权重裁剪 (Weight Clipping)
- 梯度惩罚 (Gradient Penalty)
 - 在损失中加梯度惩罚项
 - 更稳定的 Lipschitz 约束

WGAN 的关键技术

- Lipschitz 约束
- 权重裁剪 (Weight Clipping)
- 梯度惩罚 (Gradient Penalty)
- 训练更稳定
 - 损失函数有实际意义
 - 模式崩塌减少
 - 可解释性增强

- A set of small navigation icons typically found in Beamer presentations, including symbols for back, forward, search, and other slide controls.

力

A large, faint, circular watermark of Fuzhou University's seal is centered on the slide. The outer ring contains the text "FUZHOU UNIVERSITY" at the top and "福州大学" at the bottom, separated by two dots. In the center of the seal is a large white Chinese character "福". Below the character, the year "1958" is inscribed.

- **WGAN 的问题:**
 - 权重裁剪可能损害网络表达能力
 - 梯度容易消失或爆炸
 - 需要仔细调整裁剪阈值 c

力

A large, faint, circular watermark of the Fuzhou University logo is centered in the background. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top and the Chinese characters "福州大学" around the bottom, with the year "1958" in the center. In the middle of the logo is a large, stylized Chinese character "福" (Fú), which is also the first character of the word "福力" (Fúli).

- **WGAN 的问题:**
 - 权重裁剪可能损害网络表达能力
 - 梯度容易消失或爆炸
 - 需要仔细调整裁剪阈值 c
- **WGAN-GP 改进:**
 - 梯度惩罚代替权重裁剪
 - 更稳定的训练
 - 更好的理论保证

力

$\rho_{\hat{x}}[(\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1)^2]$

插值

- 其中 $\hat{x}$ 是真实样本和生成样本的插值

$$\lambda \cdot \mathbb{E}_{\hat{x} \sim p_{\hat{x}}}[(\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1)^2]$$

其中 $\hat{x}$ 是真实样本和生成样本的插值

力

$p_{\hat{x}} [(\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1)^2]$

插值

$[D(x)] + \lambda \cdot \mathbb{E}_{\hat{x} \sim p_{\hat{x}}} [(\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1)^2]$

- $$\lambda \cdot \mathbb{E}_{\hat{x} \sim p_{\hat{x}}}[(\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1)^2]$$

- **完整损失函数:**

$$L = \mathbb{E}_{\tilde{x} \sim p_q}[D(\tilde{x})] - \mathbb{E}_{x \sim p_r}[D(x)] + \lambda \cdot \mathbb{E}_{\hat{x} \sim p_{\hat{x}}}[(\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1)^2]$$

$$\begin{aligned} & \sim U[0, 1]; \\ & D(\hat{x}) ||_2 - 1)^2]; \\ & \frac{1}{m} \sum D(x^{(i)}) + GP]; \end{aligned}$$

```

for  $iteration = 1, 2, \dots$  do
  for  $t = 1, \dots, n_{critic}$  do
    采样真实数据  $\{x^{(i)}\}_{i=1}^m \sim p_r$ ;
    采样噪声  $\{z^{(i)}\}_{i=1}^m \sim p(z)$ ;
    生成假数据  $\tilde{x}^{(i)} = G(z^{(i)})$ ;
    插值  $\hat{x}^{(i)} = \epsilon x^{(i)} + (1 - \epsilon) \tilde{x}^{(i)}, \epsilon \sim U[0, 1]$ ;
    计算梯度惩罚  $GP = \lambda \cdot \mathbb{E}_{\hat{x}}[(\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1)^2]$ ;
    更新判别器:  $\nabla_w[\frac{1}{m} \sum D(\tilde{x}^{(i)}) - \frac{1}{m} \sum D(x^{(i)}) + GP]$ ;
  采样噪声  $\{z^{(i)}\}_{i=1}^m \sim p(z)$ ;
  更新生成器:  $\nabla_{\theta}[-\frac{1}{m} \sum D(G(z^{(i)}))]$ ;

```

算法	训练稳定	模式崩塌	超参数敏感
原始 GAN	差	严重	高
WGAN	中等	减少	中等
WGAN-GP	好	很少	低

GAN 变体对比

GAN 变体对比

- 优先使用 WGAN-GP
- λ 通常取 10
- 判别器更新次数 n_{critic} 通常为 5

A large, faint watermark of the Fuzhou University logo is centered on the slide. The logo is circular, featuring the text "FUZHOU UNIVERSITY" around the top and "福州" (Fuzhou) around the bottom. In the center is a large Chinese character "福" (Fú), which is stylized to incorporate a graduation cap. Below the character "福" is the year "1958". At the very bottom of the slide, there is a small navigation bar with several icons: a square, a circle, a triangle, and some symbols resembling arrows or document icons.

三种 GAN 对比

- **原始 GAN**: 简单, 开山之作
 - 缺点: 训练不稳定, 模式崩塌
 - 适用: 基础教学, 简单任务

A large, faint, circular watermark of the Fuzhou University logo is centered on the slide. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top and the Chinese characters "福州大学" around the bottom, with the year "1958" in the center. A large, stylized Chinese character "福" (Fú) is prominently displayed in the middle of the logo.

- **原始 GAN**: 简单, 开山之作
 - 缺点: 训练不稳定, 模式崩塌
 - 适用: 基础教学, 简单任务
- **cGAN**: 可控生成, 多样性好
 - 缺点: 需要条件信息
 - 适用: 有条件生成任务

A large, faint, circular watermark of the Fuzhou University logo is centered on the slide. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top and the Chinese characters "福州大学" around the bottom, with the year "1958" in the center. The character "福" (Fú) is prominently displayed in the middle.

- **原始 GAN**: 简单, 开山之作
 - 缺点: 训练不稳定, 模式崩塌
 - 适用: 基础教学, 简单任务
- **cGAN**: 可控生成, 多样性好
 - 缺点: 需要条件信息
 - 适用: 有条件生成任务
- **WGAN**: 训练稳定, 理论坚实
 - 缺点: 计算稍复杂
 - 适用: 实际应用, 质量要求高

如何选择 GAN 变体

- 需要可控生成 → cGAN

- **原始 GAN**: 简单, 开山之作
 - 缺点: 训练不稳定, 模式崩塌
 - 适用: 基础教学, 简单任务
- **cGAN**: 可控生成, 多样性好
 - 缺点: 需要条件信息
 - 适用: 有条件生成任务
- **WGAN**: 训练稳定, 理论坚实
 - 缺点: 计算稍复杂
 - 适用: 实际应用, 质量要求高

- 需要可控生成 → cGAN

如何选择 GAN 变体

- 需要可控生成 → cGAN
- 需要高质量生成 → WGAN-GP

- **原始 GAN**: 简单, 开山之作
 - 缺点: 训练不稳定, 模式崩塌
 - 适用: 基础教学, 简单任务
- **cGAN**: 可控生成, 多样性好
 - 缺点: 需要条件信息
 - 适用: 有条件生成任务
- **WGAN**: 训练稳定, 理论坚实
 - 缺点: 计算稍复杂
 - 适用: 实际应用, 质量要求高

- 需要可控生成 → cGAN
- 需要高质量生成 → WGAN-GP

如何选择 GAN 变体

- 需要可控生成 → cGAN
- 需要高质量生成 → WGAN-GP
- 数据量小 → 原始 GAN+正则化

- **原始 GAN**: 简单, 开山之作
 - 缺点: 训练不稳定, 模式崩塌
 - 适用: 基础教学, 简单任务
- **cGAN**: 可控生成, 多样性好
 - 缺点: 需要条件信息
 - 适用: 有条件生成任务
- **WGAN**: 训练稳定, 理论坚实
 - 缺点: 计算稍复杂
 - 适用: 实际应用, 质量要求高

- 需要可控生成 → cGAN
- 需要高质量生成 → WGAN-GP
- 数据量小 → 原始 GAN+正则化

如何选择 GAN 变体

- 需要可控生成 → cGAN
- 需要高质量生成 → WGAN-
- 数据量小 → 原始 GAN+正则
- 训练不稳定 → WGAN-GP

- **原始 GAN**: 简单, 开山之作
 - 缺点: 训练不稳定, 模式崩塌
 - 适用: 基础教学, 简单任务
- **cGAN**: 可控生成, 多样性好
 - 缺点: 需要条件信息
 - 适用: 有条件生成任务
- **WGAN**: 训练稳定, 理论坚实
 - 缺点: 计算稍复杂
 - 适用: 实际应用, 质量要求高

- 需要可控生成 → cGAN
- 需要高质量生成 → WGAN-GP
- 数据量小 → 原始 GAN+正则化
- 训练不稳定 → WGAN-GP

三种 GAN 对比

- **原始 GAN**: 简单, 开山之作
 - 缺点: 训练不稳定, 模式崩塌
 - 适用: 基础教学, 简单任务
- **cGAN**: 可控生成, 多样性好
 - 缺点: 需要条件信息
 - 适用: 有条件生成任务
- **WGAN**: 训练稳定, 理论坚实
 - 缺点: 计算稍复杂
 - 适用: 实际应用, 质量要求高

如何选择 GAN 变体

- 需要可控生成 $\rightarrow$ cGAN
- 需要高质量生成 $\rightarrow$ WGAN-GP
- 数据量小 $\rightarrow$ 原始 GAN+正则化
- 训练不稳定 $\rightarrow$ WGAN-GP
- 需要多样性 $\rightarrow$ cGAN+多样性损失

时空数据中的 GAN 应用

- **交通数据生成**
 - 生成逼真交通流量
 - 数据增强
 - 异常检测

- **原始 GAN**: 简单, 开山之作
 - 缺点: 训练不稳定, 模式崩塌
 - 适用: 基础教学, 简单任务
- **cGAN**: 可控生成, 多样性好
 - 缺点: 需要条件信息
 - 适用: 有条件生成任务
- **WGAN**: 训练稳定, 理论坚实
 - 缺点: 计算稍复杂
 - 适用: 实际应用, 质量要求高

- **交通数据生成**
 - 生成逼真交通流量
 - 数据增强
 - 异常检测

三种 GAN 对比

- **原始 GAN**: 简单, 开山之作
 - 缺点: 训练不稳定, 模式崩塌
 - 适用: 基础教学, 简单任务
- **cGAN**: 可控生成, 多样性好
 - 缺点: 需要条件信息
 - 适用: 有条件生成任务
- **WGAN**: 训练稳定, 理论坚实
 - 缺点: 计算稍复杂
 - 适用: 实际应用, 质量要求高

时空数据中的 GAN 应用

- 交通数据生成
- 气象数据生成
 - 生成气象场
 - 极端天气模拟
 - 气象预报

时空数据中的 GAN 应用

- 交通数据生成
- 气象数据生成
- 视频生成
 - 生成连续视频帧
 - 视频预测
 - 视频超分辨率

- **原始 GAN**: 简单, 开山之作
 - 缺点: 训练不稳定, 模式崩塌
 - 适用: 基础教学, 简单任务
- **cGAN**: 可控生成, 多样性好
 - 缺点: 需要条件信息
 - 适用: 有条件生成任务
- **WGAN**: 训练稳定, 理论坚实
 - 缺点: 计算稍复杂
 - 适用: 实际应用, 质量要求高

- 交通数据生成
- 气象数据生成
- 视频生成
 - 生成连续视频帧
 - 视频预测
 - 视频超分辨率

时空数据中的 GAN 应用

- 交通数据生成
- 气象数据生成
- 视频生成
- 轨迹数据生成
 - 生成移动轨迹
 - 轨迹预测
 - 隐私保护

A set of small navigation icons typically found in Beamer presentations, including symbols for back, forward, search, and other slide controls.

时空 GAN 的关键技术

- 时空卷积/反卷积
- 递归神经网络
- 注意力机制
- 多尺度生成
- 条件生成（时间、空间条件）

- **原始 GAN**: 简单, 开山之作
 - 缺点: 训练不稳定, 模式崩塌
 - 适用: 基础教学, 简单任务
- **cGAN**: 可控生成, 多样性好
 - 缺点: 需要条件信息
 - 适用: 有条件生成任务
- **WGAN**: 训练稳定, 理论坚实
 - 缺点: 计算稍复杂
 - 适用: 实际应用, 质量要求高

- 时空卷积/反卷积
- 递归神经网络
- 注意力机制
- 多尺度生成
- 条件生成（时间、空间条件）

全

A large, faint, circular watermark of the Fuzhou University logo is centered in the background. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top arc and in Chinese, "福州大学", around the bottom arc, with the founding year "1958" at the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú).

- 生成逼真的交通流量数据
- 补全缺失的传感器数据
- 数据增强：生成稀缺场景数据
- 多尺度时空模式学习

- 生成逼真的交通流量数据
- 补全缺失的传感器数据
- 数据增强：生成稀缺场景数据
- 多尺度时空模式学习

- 生成逼真的交通流量数据
 - 补全缺失的传感器数据
 - 数据增强：生成稀缺场景数据
 - 多尺度时空模式学习
- 构特点：**
- 图卷积生成器：捕获空间依赖
 - 递归神经网络：建模时间演化
 - 条件生成：基于时间、天气等条件
 - 对抗训练：确保数据真实性

全

条件

A large, faint, circular watermark of the Fuzhou University logo is centered in the background. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top arc and in Chinese, "福州大学", around the bottom arc, with the year "1958" at the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú), which is also the title of the presentation.

- A set of small navigation icons typically found in Beamer presentations, including symbols for back, forward, search, and other slide controls.

- **ClimaGAN: 气象数据生成**
 - 生成高分辨率气象场
 - 极端天气事件模拟
 - 气象数据降尺度
 - 不确定性量化

- **ClimaGAN: 气象数据生成**

- 生成高分辨率气象场
- 极端天气事件模拟
- 气象数据降尺度
- 不确定性量化

A large, faint, circular watermark of Fuzhou University's seal is visible in the background. The seal contains the university's name in Chinese characters '福州大学' and the year '1958'.

全

- **ClimaGAN：气象数据生成**

- 生成高分辨率气象场
- 极端天气事件模拟
- 气象数据降尺度
- 不确定性量化

- **关键技术：**

- 物理约束生成：遵循物理定律
- 多变量联合生成：温度、降水、风速等
- 条件生成：基于初始条件和边界条件
- 评估指标：CRPS、能量谱分数


条件

◀ ◻ ▶ ◻ ▶ ◻ ▶ ◻ ▶

- 物理约束生成：遵循物理定律
- 多变量联合生成：温度、降水、风速等
- 条件生成：基于初始条件和边界条件
- 评估指标：CRPS、能量谱分数等

● **核心思想：完形填空**

- 随机遮掩句子中的单词
- 让模型预测被遮掩的单词
- 无需人工标注，自监督学习



BERT 的掩码语言模型

- **核心思想：完形填空**
 - 随机遮掩句子中的单词
 - 让模型预测被遮掩的单词
 - 无需人工标注，自监督学习
- **技术突破：**
 - 双向编码（之前：单向语言模型）
 - Transformer 架构（并行计算）
 - 大规模预训练+微调

BERT 的掩码语言模型


-
- Masked Language Modeling MLM**
- flame stickers make cars go faster
- BERT-like language model
- flame stickers make <MASK> go faster
- flame stickers make cars go faster

BERT 的掩码语言模型

- **核心思想：**完形填空
 - 随机遮掩句子中的单词
 - 让模型预测被遮掩的单词
 - 无需人工标注，自监督学习
- **技术突破：**
 - 双向编码（之前：单向语言模型）
 - Transformer 架构（并行计算）
 - 大规模预训练+微调
- **训练目标：**
$$\mathcal{L}_{\text{MLM}} = - \sum_{i \in M} \log P(x_i | \mathbf{x}_{\setminus M})$$

其中 M 是被遮掩位置的集合

The diagram illustrates the concept of Masked Language Modeling (MLM) and its implementation in BERT. At the top, the title 'Masked Language Modeling MLM' is shown. Below it, a sequence of words is presented in boxes: 'flame', 'stickers', 'make', 'cars', 'go', and 'faster'. The word 'cars' is highlighted in yellow, indicating it is the masked token. Below this sequence is a large yellow box labeled 'BERT-like language model'. Arrows point from each word box to the central model box. Below the model box, the same sequence of words is shown again, but the masked token 'cars' is replaced by '<MASK>', which is also highlighted in yellow. Arrows point from each word box to the masked sequence below. At the bottom, the text 'BERT 的掩码语言模型' (BERT's masked language model) is displayed.



Navigation icons: back, forward, search, and other controls.

A large, faint, circular watermark of the Fuzhou University logo is centered on the slide. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top and the Chinese characters "福州大学" around the bottom. In the center is a large stylized character "福" (Fú) and the year "1958".

三步掩码策略 (15%规则)

- **第一步：随机选择 15%的单词**

A large, faint watermark of the Fuzhou University logo is centered on the slide. The logo is circular, featuring the university's name in English, "FUZHOU UNIVERSITY", around the top and the Chinese characters "福州大学" around the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú), which means "blessing" or "good fortune". Below the character "福" is the year "1958". The entire logo is rendered in a light gray color, serving as a background element.

三步掩码策略 (15%规则)

- **第一步**: 随机选择 15%的单词
- **第二步**: 对选中的单词进行处理
 - 80% → 替换为 [MASK]
 - 10% → 替换为随机单词
 - 10% → 保持不变

A large, faint, circular watermark of the Fuzhou University logo is centered on the slide. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top arc and in Chinese, "福州大学", around the bottom arc, with the founding year "1958" at the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú).

三步掩码策略 (15%规则)

- **第一步**: 随机选择 15%的单词
- **第二步**: 对选中的单词进行处理
 - 80% → 替换为 [MASK]
 - 10% → 替换为随机单词
 - 10% → 保持不变
- **第三步**: 让模型预测原始单词

BERT 的掩码策略详解

三步掩码策略 (15%规则)

- **第一步**: 随机选择 15%的单词
- **第二步**: 对选中的单词进行处理
 - 80% → 替换为 [MASK]
 - 10% → 替换为随机单词
 - 10% → 保持不变
- **第三步**: 让模型预测原始单词

为什么这样设计？

- **80%掩码**：核心学习任务

ASK]

A set of small navigation icons typically found in Beamer presentations, including symbols for back, forward, search, and other slide controls.

ASK]

- 10%不变：学习真实上下文

Navigation icons: back, forward, search, etc.

三步掩码策略 (15%规则)

- **第一步**: 随机选择 15%的单词
- **第二步**: 对选中的单词进行处理
 - 80% → 替换为 [MASK]
 - 10% → 替换为随机单词
 - 10% → 保持不变
- **第三步**: 让模型预测原始单词

为什么这样设计?

- **80%掩码**：核心学习任务
- **10%随机替换**：防止过拟合 [MASK]
- **10%不变**：学习真实上下文

A large, faint, circular watermark of Fuzhou University's logo is centered in the background. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top arc and the Chinese characters "福州大学" (Fuzhou University) in the center. A small red square is located in the upper left corner of the slide.

- **10%不变**：学习真实上下文
- **平衡暴露偏差** (Exposure Bias)

暴露偏差问题


- 训练时：看到 [MASK] token
- 测试时：看不到 [MASK]，只单词
- 10%不变 + 10%随机：让模型真实上下文
- 提高模型在实际应用中的鲁棒性

暴露偏差问题

- ## 为什么这样设计？

- **10%不变**：学习真实上下文
- **平衡暴露偏差** (Exposure Bias)

- **核心问题：**如何为位置点学习有意义的嵌入表示？



CTLE 模型框架


- **核心问题：**如何为位置点学习有意义的嵌入表示？
- **关键洞察：**
 - 位置点的语义受上下文影响
 - 相同位置在不同时间有不同语义
 - 需要同时建模空间、时间、上下文

```

graph TD
    A["用户轨迹数据  
[[l1, t1, c1], ..., [ln, tn, cn]]"] --> B["掩码位置  
预测"]
    A --> C["位置-时间  
匹配"]
    A --> D["位置-上下文  
匹配"]
    B -- "MLM 扩展  
预测被掩码位置" --> E["联合优化  
L = λ1L_mask + λ2L_time + λ3L_context"]
    C -- "判断位置  
与时间是否匹配" --> E
    D -- "判断位置  
与上下文是否匹配" --> E
    E --> F(["通用位置嵌入  
e_l, e_t, e_c"])
    F --> G["下游任务  
下一位置预测"]
  
```

CTLE 模型框架

- 授课教师：柯嵩宇




- **核心问题：**如何为位置点学习有意义的嵌入表示？
- **关键洞察：**
 - 位置点的语义受上下文影响
 - 相同位置在不同时间有不同语义
 - 需要同时建模空间、时间、上下文
- **模型目标：**
 - 预训练：学习通用位置嵌入
 - 微调：用于下游任务（如下一位置预测）
 - 自监督：无需人工标注

```


graph TD
    A["用户轨迹数据  
[[l1, t1, c1), ..., (ln, tn, cn)]]"] --> B["掩码位置  
预测"]
    A --> C["位置-时间  
匹配"]
    A --> D["位置-上下文  
匹配"]
    B -- "MLM 扩展  
预测被掩码位置" --> E["联合优化  
L = λ1Lmask + λ2Ltime + λ3Lcontext"]
    C -- "判断位置  
与时间是否匹配" --> E
    D -- "判断位置  
与上下文是否匹配" --> E
    E --> F(["通用位置嵌入  
el, et, ec"])
    F --> G["下游任务  
下一位置预测"]
  
```

CTLE 模型框架



CTLE 模型框架

- **核心问题：**如何为位置点学习有意义的嵌入表示？
- **关键洞察：**
 - 位置点的语义受上下文影响
 - 相同位置在不同时间有不同语义
 - 需要同时建模空间、时间、上下文
- **模型目标：**
 - 预训练：学习通用位置嵌入
 - 微调：用于下游任务（如下一位置预测）
 - 自监督：无需人工标注
- **三个预训练任务：**掩码位置预测（MLM 扩展）、位置-时间匹配、位置-上下文匹配



CTLE 模型框架

时空轨迹

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ≡ ↺ 🔍 ↻

时空轨迹

置 ID)
)
天气等)
)

A large, faint watermark of Fuzhou University's circular seal is centered in the background. The seal contains the university's name in English ('FUZHOU UNIVERSITY'), the large Chinese character '福' (Fú), and the founding year '1958' at the bottom.

- # 时空轨迹
- 置 ID)
)
天气等)
)
- 
- A large, faint watermark of Fuzhou University's logo is centered in the background. It features a circular emblem with the university's name in English, "FUZHOU UNIVERSITY", around the top and the Chinese characters "福州大学" around the bottom. In the center of the emblem is a large, stylized white character "福" (Fú). Below the emblem, the year "1958" is visible. At the very bottom of the slide, there is a row of small navigation icons: a square, a circle, a triangle, and a set of four arrows pointing left and right.

时空轨迹

置 ID)

天气等)

人)

文信息

- 时空轨迹
- 置 ID)
- 天气等)
- 人)
- 文信息

时空轨迹
(位置 ID)
(天气等)
(人)

文本信息

上下文 (前后位置、时间、上下文信息), 预测

- **类比 BERT 的 MLM:** 但针对时空轨迹
- **输入表示:**
 - 位置嵌入: e_l (离散化后的位置 ID)
 - 时间嵌入: e_t (时间段的嵌入)
 - 上下文嵌入: e_c (POI 类别、天气等)
 - 用户嵌入: e_u (用户 ID 的嵌入)
- **掩码策略:**
 - 随机遮掩轨迹中的某些位置点
 - 遮掩比例: 15-30%
 - 只遮掩位置, 保留时间和上下文信息
- **模型任务:** 给定被遮掩位置的上下文 (前后位置、时间、上下文信息), 预测被遮掩的位置 ID

68 / 89

正样本

餐厅@12:00

负样本 (错误时间)

餐厅@03:00

匹配模型

$$f(l, t) = \sigma(\mathbf{e}_l^T \mathbf{e}_t)$$

输出: 1 (匹配)

餐厅在中午
开放且忙碌

输出: 0 (不匹配)

餐厅在凌晨
通常关闭

位置-时间匹配任务

-
- | 正样本 | 负样本 | |
|---|----------------|--------------------|
| | (错误时间) | (错误位置) |
| 餐厅@12:00 | 餐厅@03:00 | 学校@12:00 |
| ↓ 匹配 | ↓ 不匹配 | ↓ 不匹配 |
| <p>匹配模型</p> $f(l, t) = \sigma(\mathbf{e}_l^T \mathbf{e}_t)$ | | |
| ↓ | ↓ | ↓ |
| 输出: 1
(匹配) | 输出: 0
(不匹配) | 输出: 0
(不匹配) |
| 餐厅在中午
开放且忙碌 | 餐厅在凌晨
通常关闭 | 学校在中午
可能开放但语义不同 |

位置-时间匹配任务

正样本

餐厅@12:00

匹配

负样本 (错误时间)

餐厅@03:00

不匹配

匹配模型

$$f(l, t) = \sigma(\mathbf{e}_l^T \mathbf{e}_t)$$

输出: 1 (匹配)

餐厅在中午开放且忙碌


输出: 0 (不匹配)

餐厅在凌晨通常关闭

位置-时间匹配任务

- ## 位置-时间匹配任务

- **核心思想：**位置语义受上下文影响



位置-上下文匹配任务

- **核心思想：**位置语义受上下文影响
- **上下文信息：**
 - POI 类别：餐厅、商场、学校等
 - 天气：晴天、雨天、雪天
 - 事件：节假日、工作日、特殊活动
 - 社交信息：与谁一起

正样本 负样本 负样本

正样本	负样本	负样本
餐厅@生日庆祝	餐厅@商务会议	学校@下雨天

↓ ↓ ↓

匹配模型
 $f(l, c) = \sigma(e_l^T e_c)$

↓ ↓ ↓

输出：1 (匹配) 输出：0 (不匹配) 输出：0 (不匹配)

餐厅适合生日庆祝 该餐厅可能不适合商务会议 学校与下雨天没有必然联系

上下文嵌入 e_c 学习
POI 类别、天气、事件等语义

位置-上下文匹配任务

-
- 正样本** **负样本** **负样本**
- | | | |
|---------|---------|--------|
| 餐厅@生日庆祝 | 餐厅@商务会议 | 学校@下雨天 |
|---------|---------|--------|
- ↓ ↓ ↓
- 匹配模型**

$$f(l, c) = \sigma(e_l^T e_c)$$
- ↓ ↓ ↓
- 输出：1 (匹配) 输出：0 (不匹配) 输出：0 (不匹配)
- 餐厅适合生日庆祝 该餐厅可能不适合商务会议 学校与下雨天没有必然联系
- 上下文嵌入 e_c 学习
 POI 类别、天气、事件等语义

位置-上下文匹配任务

正样本 **负样本** **负样本**

餐厅@生日庆祝 餐厅@商务会议 学校@下雨天

↓ ↓ ↓

匹配模型
 $f(l, c) = \sigma(\mathbf{e}_l^T \mathbf{e}_c)$

↓ ↓ ↓

输出: 1 (匹配) 输出: 0 (不匹配) 输出: 0 (不匹配)

餐厅适合生日庆祝 该餐厅可能不适合商务会议 学校与下雨天没有必然联系

上下文嵌入 $\mathbf{e}_c$ 学习
 POI 类别、天气、事件等语义


位置-上下文匹配任务

-
- | 正样本 | 负样本 | 负样本 |
|---------|---------|--------|
| 餐厅@生日庆祝 | 餐厅@商务会议 | 学校@下雨天 |
- ↓ ↓ ↓
- 匹配模型**

$$f(l, c) = \sigma(\mathbf{e}_l^T \mathbf{e}_c)$$
- ↓ ↓ ↓
- | | | |
|---------------|----------------|----------------|
| 输出: 1
(匹配) | 输出: 0
(不匹配) | 输出: 0
(不匹配) |
| 餐厅适合生日庆祝 | 该餐厅可能不适合商务会议 | 学校与下雨天没有必然联系 |
- 上下文嵌入 $\mathbf{e}_c$ 学习
POI 类别、天气、事件等语义

位置-上下文匹配任务

- 时空数据挖掘



A large, faint, circular watermark of the Fuzhou University logo is centered on the page. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top arc and in Chinese, "福州大学", around the bottom arc, with the year "1958" at the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú). A small, solid red square is positioned on the left side of the page, partially overlapping the watermark. At the bottom right corner, there is a small navigation bar with several icons: a square, a circle, a triangle, and a set of three horizontal lines, each with a small arrow pointing to the right.

◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ◀ ↺ 🔍 ↻

A large, faint, circular watermark of the Fuzhou University logo is centered on the page. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top and the Chinese characters "福州大学" around the bottom. In the center is a large stylized character "福" (Fú) and the year "1958". A small red square is visible on the left edge of the page.

传统文本 MLM 的局限性

- **单一维度**: 只处理文本序列
- **离散符号**: 有限的词汇表

A large, faint, circular watermark of the Fuzhou University logo is centered on the slide. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top arc and in Chinese, "福州大学", around the bottom arc, with the year "1958" at the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú), which means "blessing" or "good fortune". The watermark is light gray and serves as a background element.

传统文本 MLM 的局限性

- **单一维度**: 只处理文本序列
- **离散符号**: 有限的词汇表
- **静态语义**: 单词语义不随时间变化

A large, faint watermark of the Fuzhou University logo is centered on the slide. The logo is circular, featuring the university's name in English, "FUZHOU UNIVERSITY", around the top and the Chinese characters "福州大学" around the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú), which means "blessing" or "good fortune". Below the character "福" is the year "1958". The entire logo is rendered in a light gray color, serving as a background element.

传统文本 MLM 的局限性

- **单一维度**：只处理文本序列
- **离散符号**：有限的词汇表
- **静态语义**：单词语义不随时间变化
- **缺乏上下文**：不考虑外部环境

A large, faint, circular watermark of the Fuzhou University logo is centered on the page. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top arc and in Chinese, "福州大学", around the bottom arc. The year "1958" is positioned at the bottom center of the circle. In the middle of the logo is a large, stylized Chinese character "福" (Fú), which is also the name of the book. A small red square is located on the left edge of the page, partially overlapping the logo. At the bottom right, there is a small navigation bar with several icons: a left arrow, a square, a right arrow, a magnifying glass, a list icon, and a refresh icon.

传统文本 MLM 的局限性

- **单一维度**：只处理文本序列
- **离散符号**：有限的词汇表
- **静态语义**：单词语义不随时间变化
- **缺乏上下文**：不考虑外部环境
- **序列建模**：仅考虑线性顺序

CTLE 的核心创新

CTLE 的核心创新

- **单一维度**：只处理文本序列
- **离散符号**：有限的词汇表
- **静态语义**：单词语义不随时间变化
- **缺乏上下文**：不考虑外部环境
- **序列建模**：仅考虑线性顺序

CTLE 的核心创新

- **多模态输入：** 位置+时间+上下文

CTLE 的核心创新

- **单一维度**：只处理文本序列
- **离散符号**：有限的词汇表
- **静态语义**：单词语义不随时间变化
- **缺乏上下文**：不考虑外部环境
- **序列建模**：仅考虑线性顺序

- **多模态输入：位置+时间+上下文**

CTLE 的核心创新

- **多模态输入：** 位置+时间+上下文
- **时空感知：** 位置语义随时间变化

CTLE 的核心创新

- **多模态输入**: 位置+时间+上下文
- **时空感知**: 位置语义随时间变化

CTLE 的核心创新

- **多模态输入：** 位置+时间+上下文
- **时空感知：** 位置语义随时间变化
- **上下文感知：** 位置语义受环境

CTLE 的核心创新

- **单一维度**：只处理文本序列
- **离散符号**：有限的词汇表
- **静态语义**：单词语义不随时间变化
- **缺乏上下文**：不考虑外部环境
- **序列建模**：仅考虑线性顺序

- **多模态输入**：位置+时间+上下文
- **时空感知**：位置语义随时间变化
- **上下文感知**：位置语义受环境影响

CTLE 的核心创新

- **多模态输入**：位置+时间+上下文
- **时空感知**：位置语义随时间变化
- **上下文感知**：位置语义受环境影响
- **多任务学习**：三个互补的预训练任务

70 / 89

CTLE 的核心创新

- **多模态输入**：位置+时间+上下文
- **时空感知**：位置语义随时间变化
- **上下文感知**：位置语义受环境变化影响
- **多任务学习**：三个互补的预训练任务
- **层次化表示**：学习通用位置嵌入

- **单一维度**：只处理文本序列
- **离散符号**：有限的词汇表
- **静态语义**：单词语义不随时间变化
- **缺乏上下文**：不考虑外部环境
- **序列建模**：仅考虑线性顺序

- **多模态输入**：位置+时间+上下文
- **时空感知**：位置语义随时间变化
- **上下文感知**：位置语义受环境影响
- **多任务学习**：三个互补的预训练任务
- **层次化表示**：学习通用位置嵌入

MLM	CTLE
序列 (几万)	时空轨迹
态	位置点+时间+上下文
子内	动态 (随时间变化)
MLM)	多维度外部上下文
概率	多任务 (3 个)
任务	位置嵌入
	时空预测

特征	传统 MLM	CTLE
输入类型	文本序列	时空轨迹
词汇表	有限 (几万)	位置点+时间+上下文
语义动态性	静态	动态 (随时间变化)
上下文考虑	句子内	多维度外部上下文
预训练任务	单一 (MLM)	多任务 (3 个)
输出目标	单词概率	位置嵌入
应用场景	NLP 任务	时空预测

CTLE 的技术贡献

- 1 首次将 MLM 思想系统应用于时空轨迹
- 2 提出位置-时间-上下文联合建模框架
- 3 设计三个互补的预训练任务
- 4 学习通用、可迁移的位置嵌入
- 5 在下游任务上显著提升性能

时空 MLM 相关工作

- **ST-LSTM (KDD18):** 融合空间-时间-语义特征

时空 MLM 相关工作

- **ST-LSTM** (KDD18): 融合空间-时间-语义特征
- **GeoTransformer** (WWW22): 地理空间 Transformer

时空 MLM 相关工作

- **ST-LSTM** (KDD18): 融合空间-时间-语义特征
- **GeoTransformer** (WWW22): 地理空间 Transformer
- **TrajFormer** (KDD23): 轨迹预训练大模型

时空 MLM 相关工作

- **ST-LSTM** (KDD18): 融合空间-时间-语义特征
- **GeoTransformer** (WWW22): 地理空间 Transformer
- **TrajFormer** (KDD23): 轨迹预训练大模型
- **SpatioBERT** (ICDE22): 面向地理文本的预训练

- **ST-LSTM** (KDD18): 融合空间-时间-语义特征
- **GeoTransformer** (WWW22): 地理空间 Transformer
- **TrajFormer** (KDD23): 轨迹预训练大模型
- **SpatioBERT** (ICDE22): 面向地理文本的预训练
- **TimeTraj** (SIGSPATIAL21): 时间感知轨迹表示

时空 MLM 相关工作

- **ST-LSTM** (KDD18): 融合空间-时间-语义特征
- **GeoTransformer** (WWW22): 地理空间 Transformer
- **TrajFormer** (KDD23): 轨迹预训练大模型
- **SpatioBERT** (ICDE22): 面向地理文本的预训练
- **TimeTraj** (SIGSPATIAL21): 时间感知轨迹表示

研究趋势

相关研究与扩展

时空 MLM 相关工作

- **ST-LSTM** (KDD18): 融合空间-时间-语义特征
- **GeoTransformer** (WWW22): 地理空间 Transformer
- **TrajFormer** (KDD23): 轨迹预训练大模型
- **SpatioBERT** (ICDE22): 面向地理文本的预训练
- **TimeTraj** (SIGSPATIAL21): 时间感知轨迹表示

研究趋势

- ## ● 从单一轨迹到多模态融合

时空 MLM 相关工作

- **ST-LSTM** (KDD18): 融合空间-时间-语义特征
- **GeoTransformer** (WWW22): 地理空间 Transformer
- **TrajFormer** (KDD23): 轨迹预训练大模型
- **SpatioBERT** (ICDE22): 面向地理文本的预训练
- **TimeTraj** (SIGSPATIAL21): 时间感知轨迹表示

研究趋势

- 从单一轨迹到多模态融合
- 从小规模预训练到基础模型
- 从预测任务到生成任务

发展历程

- **2018: BERT 提出掩码语言模型 (MLM)**
 - 随机掩码文本标记
 - 自监督预训练



Masked AutoEncoder: 历史发展

发展历程

- **2018:** BERT 提出掩码语言模型 (MLM)
 - 随机掩码文本标记
 - 自监督预训练
- **2020:** ViT 将 Transformer 应用于图像
 - 图像分块处理
 - 全局注意力机制



Masked AutoEncoder: 历史发展

发展历程

- **2018:** BERT 提出掩码语言模型 (MLM)
 - 随机掩码文本标记
 - 自监督预训练
- **2020:** ViT 将 Transformer 应用于图像
 - 图像分块处理
 - 全局注意力机制
- **2021:** MAE 正式提出 (Kaiming He et al.)
 - 结合 BERT 掩码思想与 ViT 架构
 - 高比例随机掩码 (75%)

发展历程


- **2018:** BERT 提出掩码语言模型 (MLM)
 - 随机掩码文本标记
 - 自监督预训练
- **2020:** ViT 将 Transformer 应用于图像
 - 图像分块处理
 - 全局注意力机制
- **2021:** MAE 正式提出 (Kaiming He et al.)
 - 结合 BERT 掩码思想与 ViT 架构
 - 高比例随机掩码 (75%)

核心突破

MAE 首次将高比例随机掩码与不对称编解码架构结合，实现高效的视觉表征学习。

核心设计原则


- **高掩码率**: 75%的 patches 被随机掩码
 - 迫使模型学习全局表示
 - 减少冗余信息学习



MAE 架构示意图

核心设计原则


- **高掩码率**：75%的 patches 被随机掩码
 - 迫使模型学习全局表示
 - 减少冗余信息学习
- **不对称架构**
 - 编码器：仅处理可见 patches
 - 解码器：处理所有 patches(可见+掩码)
 - 解码器可以更轻量



MAE 架构示意图


核心设计原则

- **高掩码率**：75%的 patches 被随机掩码
 - 迫使模型学习全局表示
 - 减少冗余信息学习
- **不对称架构**
 - 编码器：仅处理可见 patches
 - 解码器：处理所有 patches(可见+掩码)
 - 解码器可以更轻量
- **非对称掩码**
 - 训练：高比例掩码 (75%)
 - 推理：无掩码或低比例掩码




核心设计原则

- **高掩码率**：75%的 patches 被随机掩码
 - 迫使模型学习全局表示
 - 减少冗余信息学习
- **不对称架构**
 - 编码器：仅处理可见 patches
 - 解码器：处理所有 patches(可见+掩码)
 - 解码器可以更轻量
- **非对称掩码**
 - 训练：高比例掩码 (75%)
 - 推理：无掩码或低比例掩码




核心设计原则

- **高掩码率**：75%的 patches 被随机掩码
 - 迫使模型学习全局表示
 - 减少冗余信息学习
- **不对称架构**
 - 编码器：仅处理可见 patches
 - 解码器：处理所有 patches(可见+掩码)
 - 解码器可以更轻量
- **非对称掩码**
 - 训练：高比例掩码 (75%)
 - 推理：无掩码或低比例掩码




核心设计原则

- **高掩码率**：75%的 patches 被随机掩码
 - 迫使模型学习全局表示
 - 减少冗余信息学习
- **不对称架构**
 - 编码器：仅处理可见 patches
 - 解码器：处理所有 patches(可见+掩码)
 - 解码器可以更轻量
- **非对称掩码**
 - 训练：高比例掩码 (75%)
 - 推理：无掩码或低比例掩码



核心设计原则

- **高掩码率**：75%的 patches 被随机掩码
 - 迫使模型学习全局表示
 - 减少冗余信息学习
- **不对称架构**
 - 编码器：仅处理可见 patches
 - 解码器：处理所有 patches(可见+掩码)
 - 解码器可以更轻量
- **非对称掩码**
 - 训练：高比例掩码 (75%)
 - 推理：无掩码或低比例掩码




MAE 架构示意图

计算效率

仅对 25%可见 patches 编码, 减少计算量 4 倍

掩码策略


- **随机均匀掩码**
 - 将图像划分为 16×16 patches
 - 随机选择 75% 的 patches 进行掩码
 - 剩余 25% 输入编码器



MAE 掩码与重建过程

掩码策略

- **随机均匀掩码**
 - 将图像划分为 16×16 patches
 - 随机选择 75% 的 patches 进行掩码
 - 剩余 25% 输入编码器
- **掩码标记处理**
 - 掩码 patches 用单一可学习向量替代
 - 不添加位置编码到掩码 tokens
 - 仅对可见 patches 添加位置编码



MAE 掩码与重建过程

$$\frac{1}{|\mathcal{M}|} \sum_{i \in \mathcal{M}} \|x_i - \hat{x}_i\|_2^2$$

其中 $\mathcal{M}$ 表示掩码 patches 集合

$$\mathcal{L} = \frac{1}{|\mathcal{M}|} \sum_{i \in \mathcal{M}} \|x_i - \hat{x}_i\|_2^2$$

其中 $\mathcal{M}$ 表示掩码 patches 集合

● 插补偏差问题

- 缺失值插补引入偏差
- 中间产物影响下游任务
- 误差传播难以控制

TriD-MAE: 面向含缺失值多元时间序列的通用预训练模型

传统两阶段流程的问题

- **插补偏差问题**
 - 缺失值插补引入偏差
 - 中间产物影响下游任务
 - 误差传播难以控制
- **训练冗余问题**
 - 特征提取重复进行
 - 多个模型独立训练
 - 计算资源浪费严重

- 线缺失 (Line Missing)
- 块缺失 (Block Missing)
- 复杂混合模式

77 / 89

78 / 89


三大核心技术

① 时间翻转技巧 (Time-Flipping)

- 双向时序卷积
- 前后向上下文融合
- 因果性约束突破

② 动态内核机制 (Dynamic Kernel)

- 输入感知卷积核
- 多候选核注意力融合
- 自适应感受野调整



TriD-TCN 单元结构

78 / 89

动态内核计算过程

$$a_d = (a_1, a_2, \dots, a_K) = W_d \left[\frac{1}{T} X_{in} 1, \frac{1}{n} X_{in}^T 1 \right] + b$$

$$\alpha_i = \frac{\exp(a_i/\lambda)}{\sum_{j=1}^K \exp(a_j/\lambda)} \quad \hat{W}_c = \sum_{i=1}^K \alpha_i \cdot W_i$$

动态内核计算过程

$$a_d = (a_1, a_2, \dots, a_K) = W_d \left[\frac{1}{T} X_{in} 1, \frac{1}{n} X_{in}^T 1 \right] + b$$

$$\alpha_i = \frac{\exp(a_i/\lambda)}{\sum_{j=1}^K \exp(a_j/\lambda)} \quad \hat{W}_c = \sum_{i=1}^K \alpha_i \cdot W_i$$

- **输入自适应**: 内核参数随输入动态调整
- **多尺度感知**: 不同时间尺度特征捕获
- **计算高效**: 注意力机制轻量计算
- **泛化性强**: 适应多样时间模式

动态内核机制的数学表达

动态内核计算过程

$$a_d = (a_1, a_2, \dots, a_K) = W_d \left[\frac{1}{T} X_{in} 1, \frac{1}{n} X_{in}^T 1 \right] + b$$

$$\alpha_i = \frac{\exp(a_i/\lambda)}{\sum_{j=1}^K \exp(a_j/\lambda)} \quad \hat{W}_c = \sum_{i=1}^K \alpha_i \cdot W_i$$

技术优势

- **输入自适应**: 内核参数随输入动态调整
- **多尺度感知**: 不同时间尺度特征捕获
- **计算高效**: 注意力机制轻量计算
- **泛化性强**: 适应多样时间模式

创新意义

- 突破传统卷积固定内核限制
- 实现真正意义上的动态卷积
- 为时序数据提供更灵活的特征提取

A large, faint, circular watermark of the Fuzhou University logo is centered on the slide. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top and the Chinese characters "福州大学" around the bottom, with the year "1958" in the center. A large, stylized Chinese character "福" (Fú) is prominently displayed in the middle of the logo. A small red square is located in the top left corner of the slide. At the bottom right, there is a navigation bar with several icons: a left arrow, a square, a right arrow, a double left arrow, a double right arrow, and a refresh/circular arrow icon.


DPE 核心思想

- **上下文感知嵌入**
 - 缺失位置语义学习
 - 时空上下文融合
 - 动态生成嵌入向量

A large, faint watermark of the Fuzhou University logo is centered on the slide. The logo is circular, featuring the university's name in English, "FUZHOU UNIVERSITY", around the top and the Chinese characters "福州大学" around the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú), which means "blessing" or "good fortune". The year "1958" is also visible at the bottom of the logo.


DPE 核心思想

- **上下文感知嵌入**
 - 缺失位置语义学习
 - 时空上下文融合
 - 动态生成嵌入向量
- **缺失模式鲁棒性**
 - 线缺失模式处理
 - 块缺失模式适应
 - 随机缺失模式优化




双路径掩码策略

- **原始数据路径**
 - 保持原始缺失模式
 - 学习真实数据分布
 - 维持时序连续性




双路径掩码策略

- **原始数据路径**
 - 保持原始缺失模式
 - 学习真实数据分布
 - 维持时序连续性
- **随机掩码路径**
 - 人工引入掩码
 - 强化 DPE 监督信号
 - 增强模型鲁棒性



- **原始数据路径**
 - 保持原始缺失模式
 - 学习真实数据分布
 - 维持时序连续性
 - **随机掩码路径**
 - 人工引入掩码
 - 强化 DPE 监督信号
 - 增强模型鲁棒性
 - **联合训练机制**
 - 双路径并行处理
 - 梯度共同反传
 - 参数共享学习

掩码数据输入策略与加权损失函数



加权损失函数设计

$$\mathcal{L} = \frac{1}{m_r + 1} \frac{\|(\hat{X}^r - X) \circ (M - M^r)\|_2}{\|M - M^r\|_2} + \frac{m_r}{m_r + 1} \frac{\|(\hat{X} - X) \circ M\|_2}{\|M\|_2}$$

A large, faint watermark of the Fuzhou University logo is centered on the slide. The logo is circular, featuring the university's name in English, "FUZHOU UNIVERSITY", around the top and the Chinese characters "福州大学" around the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú). Below the characters, the year "1958" is visible. The entire logo is rendered in a light gray color, serving as a background element.

暖机训练策略

- **Softmax 温度调节**
 - 初始高温平滑分布
 - 逐步降低温度参数
 - 避免过早陷入局部最优

暖机训练技巧与收敛优化

暖机训练策略

- **Softmax 温度调节**
 - 初始高温平滑分布
 - 逐步降低温度参数
 - 避免过早陷入局部最优
- **均匀权重初始化**
 - 替代初始 Softmax 输出
 - 平等对待所有候选核
 - 促进模型充分探索

暖机训练技巧与收敛优化

暖机训练策略

- **Softmax 温度调节**
 - 初始高温平滑分布
 - 逐步降低温度参数
 - 避免过早陷入局部最优
- **均匀权重初始化**
 - 替代初始 Softmax 输出
 - 平等对待所有候选核
 - 促进模型充分探索

- **渐进式训练**
 - 分阶段调整超参数
 - 平滑过渡到最终设置
 - 提高训练稳定性

暖机训练策略

- **Softmax 温度调节**
 - 初始高温平滑分布
 - 逐步降低温度参数
 - 避免过早陷入局部最优
- **均匀权重初始化**
 - 替代初始 Softmax 输出
 - 平等对待所有候选核
 - 促进模型充分探索

- **渐进式训练**
 - 分阶段调整超参数
 - 平滑过渡到最终设置
 - 提高训练稳定性

收敛优势

- **训练稳定性提升**
- 收敛速度加快
- 避免梯度爆炸/消失
- 提高模型重现性

步添加少量高斯噪声，经过很多步（如 1000 个固定的马尔可夫链过程）

$$x_t \sim \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t I)$$

训练一个神经网络（通常是 U-Net）学习 “撤销噪声的图像 x_0 ”。

将模型反复去噪，可以生成全新的、逼真的图像。

- $$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t I)$$

- **反向过程 (Reverse Process):** 训练一个神经网络 (通常是 U-Net) 学习 “撤销” 噪声, 从 x_T 开始, 逐步还原出清晰的图像 x_0 。
- 最终, 从纯噪声出发, 通过训练好的模型反复去噪, 可以生成全新的、逼真的图像。

训练目标：噪声预测

- 神经网络 ϵ_θ 的目标是预测在前向过程中添加的噪声 ϵ 。
- 损失函数简化为预测噪声与实际噪声的均方误差 (MSE):

- 无需逐步迭代, 可直接从 x_0 计算 x_t (重参数化技巧)。
- 定义 $\alpha_t = 1 - \beta_t$, $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ 。

$$q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I)$$

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

- 这极大提高了训练效率。

$$\mathcal{L} = \mathbb{E}_{t, x_0, \epsilon} [\|\epsilon - \epsilon_\theta(x_t, t)\|^2]$$

- 这种简化的目标在实践中效果良好且稳定 [5,8](@ref)。

生成过程

- 从随机噪声 $x_T \sim \mathcal{N}(0, I)$ 开始。
- 对于 $t = T, T-1, \dots, 1$:
- 使用模型预测噪声 $\epsilon_t(x_{t+1})$ 并

时间依赖关系，具有时空维度特征（如传感器
标准扩散模型可能无法有效捕捉数据中的时空
件进行针对性改进，使其能理解和生成具备时
空间特征的能力。
间依赖关系。

- **时序数据的特点**：数据点间存在时间依赖关系，具有时空维度特征（如传感器读数、视频帧）。
- **基础扩散模型的不足**：直接应用标准扩散模型可能无法有效捕捉数据中的时空关系。
- **改进思路**：对扩散模型的核心组件进行针对性改进，使其能理解和生成具备时空一致性的数据。
 - ① **增强网络架构**：提升模型捕捉空间特征的能力。
 - ② **引入时序嵌入**：显式地建模时间依赖关系。

A large, faint, circular watermark of the Fuzhou University logo is centered on the page. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top arc and in Chinese, "福州大学", around the bottom arc. The year "1958" is positioned at the bottom center of the circle. In the middle of the logo is a large, stylized Chinese character "福" (Fú), which is part of the university's emblem.

福

① 空间特征增强：SE-U-Net

- 在 U-Net 的每一层加入**压缩激励 (Squeeze-and-Excitation, SE)** 模块。

励
)
全连
习不

A large, faint, circular watermark of Fuzhou University's logo is centered in the background. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top arc and in Chinese, "福州大学", around the bottom arc, with the year "1958" at the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú), which means "blessing" or "good fortune". The character is white and stands out against the light red background of the logo. The entire slide has a light red background with a subtle grid pattern.

① 空间特征增强：SE-U-Net

- 在 U-Net 的每一层加入**压缩激励 (Squeeze-and-Excitation, SE) 模块**。
- SE 模块通过全局平均池化、全连接层和 Sigmoid 激活函数，学习不同特征通道的权重。

福

① 空间特征增强：SE-U-Net

- 在 U-Net 的每一层加入**压缩激励 (Squeeze-and-Excitation, SE) 模块**。
- SE 模块通过全局平均池化、全连接层和 Sigmoid 激活函数，学习不同特征通道的权重。
- 对重要特征通道进行加权，增强模型的空间特征提取能力，同时保持轻量化。

励
)
全连
习不
强模
保持

① 空间特征增强：SE-U-Net

- 在 U-Net 的每一层加入**压缩激励 (Squeeze-and-Excitation, SE) 模块**。
- SE 模块通过全局平均池化、全连接层和 Sigmoid 激活函数，学习不同特征通道的权重。
- 对重要特征通道进行加权，增强模型的空间特征提取能力，同时保持轻量化。

② 时序关系保持：时序嵌入模块

励
)
全连
习不
强模
保持
连续

① 空间特征增强：SE-U-Net

- 在 U-Net 的每一层加入**压缩激励 (Squeeze-and-Excitation, SE) 模块**。
- SE 模块通过全局平均池化、全连接层和 Sigmoid 激活函数，学习不同特征通道的权重。
- 对重要特征通道进行加权，增强模型的空间特征提取能力，同时保持轻量化。

② 时序关系保持：时序嵌入模块

- 问题：生成长序列时，需保证连续样本块之间的时序连贯性。

- ① **空间特征增强：SE-U-Net**
 - 在 U-Net 的每一层加入**压缩激励 (Squeeze-and-Excitation, SE) 模块**。
 - SE 模块通过全局平均池化、全连接层和 Sigmoid 激活函数，学习不同特征通道的权重。
 - 对重要特征通道进行加权，增强模型的空间特征提取能力，同时保持轻量化。
- ② **时序关系保持：时序嵌入模块**
 - 问题：生成长序列时，需保证连续样本块之间的时序连贯性。
 - 方法：在生成第 $k + 1$ 个样本块时，将第 k 个样本块末尾的部分序列信息，以递减权重的方式嵌入到去噪过程中。

序列信息，以递减权重的方式嵌入到去噪过程中。

- ① **空间特征增强：SE-U-Net**
 - 在 U-Net 的每一层加入**压缩激励 (Squeeze-and-Excitation, SE) 模块**。
 - SE 模块通过全局平均池化、全连接层和 Sigmoid 激活函数，学习不同特征通道的权重。
 - 对重要特征通道进行加权，增强模型的空间特征提取能力，同时保持轻量化。
- ② **时序关系保持：时序嵌入模块**
 - 问题：生成长序列时，需保证连续样本块之间的时序连贯性。
 - 方法：在生成第 $k + 1$ 个样本块时，将第 k 个样本块末尾的部分

- ① **空间特征增强：SE-U-Net**
 - 在 U-Net 的每一层加入**压缩激励 (Squeeze-and-Excitation, SE) 模块**。
 - SE 模块通过全局平均池化、全连接层和 Sigmoid 激活函数，学习不同特征通道的权重。
 - 对重要特征通道进行加权，增强模型的空间特征提取能力，同时保持轻量化。
- ② **时序关系保持：时序嵌入模块**
 - 问题：生成长序列时，需保证连续样本块之间的时序连贯性。
 - 方法：在生成第 $k+1$ 个样本块时，将第 k 个样本块末尾的部分序列信息，以递减权重的方式嵌入到去噪过程中。
 - 操作：将上一个样本块末尾的序列分段，赋予递减的权重，拼接成时序嵌入向量 e ，作为条件信息输入到 SE-U-Net 中。

- 在 U-Net 的每一层加入**压缩激励 (Squeeze-and-Excitation, SE) 模块**。
- SE 模块通过全局平均池化、全连接层和 Sigmoid 激活函数，学习不同特征通道的权重。
- 对重要特征通道进行加权，增强模型的空间特征提取能力，同时保持轻量化。

- 问题：生成序列时，需保证连续样本块之间的时序连贯性。
- 方法：在生成第 $k+1$ 个样本块时，将第 k 个样本块末尾的部分

- 操作：将上一个样本块末尾的序列分段，赋予递减的权重，拼接成时序嵌入向量 e ，作为条件信息输入到 SE-U-Net 中。

- ① **空间特征增强：SE-U-Net**
 - 在 U-Net 的每一层加入**压缩激励 (Squeeze-and-Excitation, SE) 模块**。
 - SE 模块通过全局平均池化、全连接层和 Sigmoid 激活函数，学习不同特征通道的权重。
 - 对重要特征通道进行加权，增强模型的空间特征提取能力，同时保持轻量化。
- ② **时序关系保持：时序嵌入模块**
 - 问题：生成长序列时，需保证连续样本块之间的时序连贯性。
 - 方法：在生成第 $k+1$ 个样本块时，将第 k 个样本块末尾的部分序列信息，以递减权重的方式嵌入到去噪过程中。
 - 操作：将上一个样本块末尾的序列分段，赋予递减的权重，拼接成时序嵌入向量 e ，作为条件信息输入到 SE-U-Net 中。
 - 效果：以条件生成的方式，引导模型生成与上文时序连贯的新数据。

- 操作：将上一个样本块末尾的序列分段，赋予递减的权重，拼接成时序嵌入向量 e ，作为条件信息输入到 SE-U-Net 中。
- 效果：以条件生成的方式，引导模型生成与上文时序连贯的新数据。

- ① **空间特征增强：SE-U-Net**
 - 在 U-Net 的每一层加入**压缩激励 (Squeeze-and-Excitation, SE) 模块**。
 - SE 模块通过全局平均池化、全连接层和 Sigmoid 激活函数，学习不同特征通道的权重。
 - 对重要特征通道进行加权，增强模型的空间特征提取能力，同时保持轻量化。
- ② **时序关系保持：时序嵌入模块**
 - 问题：生成长序列时，需保证连续样本块之间的时序连贯性。
 - 方法：在生成第 $k+1$ 个样本块时，将第 k 个样本块末尾的部分序列信息，以递减权重的方式嵌入到去噪过程中。
- ③ **应用示例：时序故障诊断**
 - 操作：将上一个样本块末尾的序列分段，赋予递减的权重，拼接成时序嵌入向量 e ，作为条件信息输入到 SE-U-Net 中。
 - 效果：以条件生成的方式，引导模型生成与上文时序连贯的新数据。

- ### ③ 应用示例：时序故障诊断

序列信息，以递减权重的方式嵌入到去噪过程中。

- 操作：将上一个样本块末尾的序列分段，赋予递减的权重，拼接成时序嵌入向量 e ，作为条件信息输入到 SE-U-Net 中。
- 效果：以条件生成的方式，引导模型生成与上文时序连贯的新数据。

③ 应用示例：时序故障诊断

- 针对故障样本稀缺、类别不平衡的问题。

- 针对故障样本稀缺、类别不平衡的问题。

- ① **空间特征增强：SE-U-Net**
 - 在 U-Net 的每一层加入**压缩激励 (Squeeze-and-Excitation, SE) 模块**。
 - SE 模块通过全局平均池化、全连接层和 Sigmoid 激活函数，学习不同特征通道的权重。
 - 对重要特征通道进行加权，增强模型的空间特征提取能力，同时保持轻量化。
- ② **时序关系保持：时序嵌入模块**
 - 问题：生成长序列时，需保证连续样本块之间的时序连贯性。
 - 方法：在生成第 $k+1$ 个样本块时，将第 k 个样本块末尾的部分序列信息，以递减权重的方式嵌入到去噪过程中。
- ③ **应用示例：时序故障诊断**
 - 针对故障样本稀缺、类别不平衡的问题。
 - 使用 TS-Diffusion 对少数类样本进行数据增强，平衡数据集，从而提升诊断模型的精度和鲁棒性。

- 操作：将上一个样本块末尾的序列分段，赋予递减的权重，拼接成时序嵌入向量 e ，作为条件信息输入到 SE-U-Net 中。
- 效果：以条件生成的方式，引导模型生成与上文时序连贯的新数据。

- 针对故障样本稀缺、类别不平衡的问题。
- 使用 TS-Diffusion 对少数类样本进行数据增强，平衡数据集，从而提升诊断模型的精度和鲁棒性。

② 时空自动机器学习

A large, faint, circular watermark of the Fuzhou University logo is centered on the page. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top arc and in Chinese, "福州大学", around the bottom arc. The year "1958" is positioned at the bottom center of the circle. In the middle of the logo is a large, stylized Chinese character "福" (Fú), which is a common symbol for good fortune. The entire logo is rendered in a light gray or off-white color, serving as a background element.

- 自动特征工程 (AutoFE)
- 自动模型选择 (AutoMS)
- 超参数优化 (HPO)
- 神经网络架构搜索 (NAS)
- 自动模型集成

- 自动特征工程 (AutoFE)
- 自动模型选择 (AutoMS)
- 超参数优化 (HPO)
- 神经网络架构搜索 (NAS)
- 自动模型集成

● 传统时空建模的挑战:

- 模型设计依赖专家经验
- 超参数调优耗时费力
- 不同时空任务需要定制模型
- 难以适应动态变化的时空模式

- **时空 AutoML 的优势：**
 - 自动发现最优时空特征
 - 自适应选择最适合的模型架构
 - 显著降低模型开发成本
 - 提升模型性能与泛化能力

◀ ◻ ▶ ◻ ▶ ◻ ▶ ◻ ▶ ◻ ▶ ◻ ▶ ◻ ▶ ◻ ▶

- **时空 AutoML 的优势:**
 - 自动发现最优时空特征
 - 自适应选择最适合的模型架构
 - 显著降低模型开发成本
 - 提升模型性能与泛化能力

- **时空 AutoML 的优势：**
 - 自动发现最优时空特征
 - 自适应选择最适合的模型架构
 - 显著降低模型开发成本
 - 提升模型性能与泛化能力
- **应用场景：**
 - 交通预测自动化系统
 - 环境监测自适应模型
 - 城市计算模型工厂
 - 时空异常检测自动配置

- **时空 AutoML 的优势：**
 - 自动发现最优时空特征
 - 自适应选择最适合的模型架构
 - 显著降低模型开发成本
 - 提升模型性能与泛化能力
- **应用场景：**
 - 交通预测自动化系统
 - 环境监测自适应模型
 - 城市计算模型工厂
 - 时空异常检测自动配置

A large, faint, circular watermark of the Fuzhou University logo is centered on the page. The logo features the university's name in English, "FUZHOU UNIVERSITY", around the top arc and in Chinese, "福州大学", around the bottom arc, with the year "1958" at the bottom. In the center of the logo is a large, stylized Chinese character "福" (Fú), which means "blessing" or "good fortune".

- 控制器 RNN 生成架构描述
- 训练子网络并评估性能
- 性能作为奖励反馈给控制器
- 经典方法：NAS-RL, ENAS
- 优点：搜索空间灵活
- 缺点：计算成本极高

- 控制器 RNN 生成架构描述
- 训练子网络并评估性能
- 性能作为奖励反馈给控制器
- 经典方法：NAS-RL, ENAS
- 优点：搜索空间灵活
- 缺点：计算成本极高

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ↺ 🔍 ↻

- **基于梯度的可微 NAS:**
 - 构建超网络 (Supernet)
 - 架构参数作为可学习变量
 - 通过梯度下降联合优化
 - 经典方法: DARTS, GDAS
 - 优点: 搜索效率高
 - 缺点: 内存消耗大

- **基于梯度的可微 NAS:**
 - 构建超网络 (Supernet)
 - 架构参数作为可学习变量
 - 通过梯度下降联合优化
 - 经典方法: DARTS, GDAS
 - 优点: 搜索效率高
 - 缺点: 内存消耗大

- **基于梯度的可微 NAS:**
 - 构建超网络 (Supernet)
 - 架构参数作为可学习变量
 - 通过梯度下降联合优化
 - 经典方法: DARTS, GDAS
 - 优点: 搜索效率高
 - 缺点: 内存消耗大
- **一次性 NAS 方法:**
 - 训练一个包含所有子路径的超网络
 - 通过权重共享加速搜索
 - 经典方法: One-shot NAS, SPO
 - 优点: 计算效率高
 - 缺点: 排名一致性假设

- **基于梯度的可微 NAS:**
 - 构建超网络 (Supernet)
 - 架构参数作为可学习变量
 - 通过梯度下降联合优化
 - 经典方法: DARTS, GDAS
 - 优点: 搜索效率高
 - 缺点: 内存消耗大
- **一次性 NAS 方法:**
 - 训练一个包含所有子路径的超网络
 - 通过权重共享加速搜索
 - 经典方法: One-shot NAS, SPOS
 - 优点: 计算效率高
 - 缺点: 排名一致性假设